

# Cyfrowa Rewolucja

Jakub Chojnacki

November 6, 2023

## O autorze



IBE  INSTYTUT  
BADAN  
EDUKACYJNYCH

 Billennium

# Kontakt

- ▶ **Imię i Nazwisko:** Jakub Chojnacki
- ▶ **E-mail:** james@marl.engineering
- ▶ **Strona internetowa:**  
<https://www.marl.engineering>
- ▶ **Repozytorium**  
<https://github.com/Sithael>

James Chojnacki

Reinforcing Understanding



I am deeply passionate about the **brain** and **multi-agent systems**, believing strongly that intelligence is shaped by the environment, and our human environment, in essence, is multi-agent. As an avid researcher in these fields, my work centers around exploring and understanding these complex systems and their impacts on intelligence growth and development.

# Agenda

1. Historia i rozwój AI
2. Przerwa
3. Podstawy maszynowego uczenia i głębokiego uczenia
4. QA - Sesja pytań i odpowiedzi

# Agenda

1. **Historia i rozwój AI**
2. Przerwa
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. QA - Sesja pytań i odpowiedzi

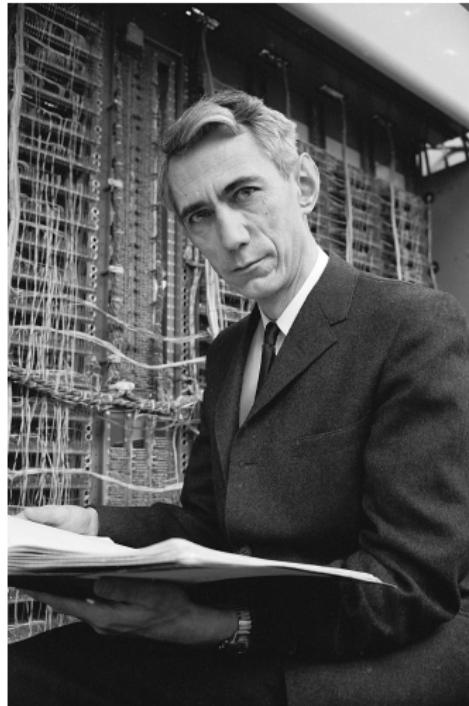
# Definicja AI

- ▶ Sztuczna inteligencja to dziedzina nauki komputerowej.
- ▶ Uczy maszyny "myśleć" i podejmować decyzje jak ludzie.
- ▶ Dzięki AI, komputery mogą:
  - ▶ Rozpoznawać obrazy.
  - ▶ Rozumieć język ludzi.
  - ▶ Grać w gry.



# Początki myśli o AI

- ▶ **Alan Turing (1940s):**
  - ▶ "Maszyna Turinga" - podstawy teoretyczne dla komputerów.
  - ▶ Test Turinga - koncepcja oceny inteligencji maszynowej.
- ▶ **Claude Shannon (1940s-50s):**
  - ▶ Twórca teorii informacji.
  - ▶ Badania nad algorytmami genetycznymi i uczeniem maszynowym.
- ▶ **John McCarthy (1950s):**
  - ▶ Wprowadzenie terminu "sztuczna inteligencja".
  - ▶ Twórca języka programowania Lisp, popularnego w badaniach nad AI.



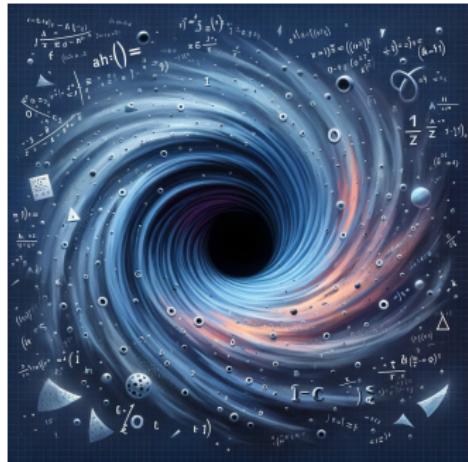
# Test Turinga

- ▶ **Zaproponowany przez Alana Turinga w 1950 r. w artykule "Computing Machinery and Intelligence".**
- ▶ **Pytanie kluczowe:** "Czy maszyny mogą myśleć?"
- ▶ Test polega na **konwersacji** między człowiekiem a maszyną ukrytą za ścianą.
- ▶ Jeśli człowiek **nie jest w stanie rozróżnić**, czy rozmawia z maszyną czy innym człowiekiem, maszyna "przechodzi" test.



# Claude Shannon i Teoria Informacji

- ▶ Entropia jest miarą niepewności lub "zaskoczenia" zawartego w danym źródle informacji.
- ▶ Wysoka entropia oznacza, że informacje są bardziej chaotyczne, nieprzewidywalne lub mają większą zawartość informacji.
- ▶ Shannon użył entropii do określenia teoretycznych limitów, jak skutecznie można kodować i przesyłać informacje.



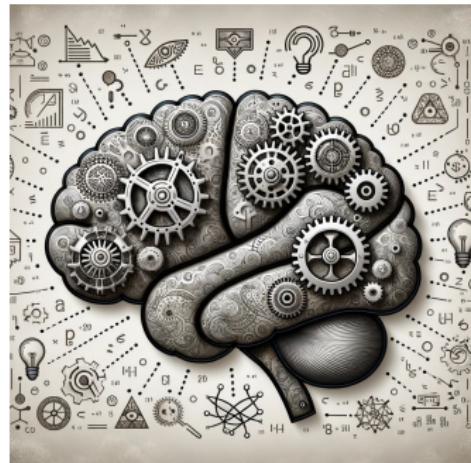
# John McCarthy i LISP

- ▶ McCarthy wymyślił słowo "sztuczna inteligencja" w 1955 roku.
- ▶ W 1958 roku stworzył język programowania LISP, który stał się popularny w tworzeniu oprogramowania AI.
- ▶ LISP pozwalał programistom łatwo manipulować symbolami i listami, co było nowością.
- ▶ McCarthy użył LISP-a do budowania programów, które mogły rozwiązywać problemy matematyczne i logiczne.



# Era Symboliki w AI

- ▶ To były początki AI, głównie lata 50., 60. i 70. XX wieku.
- ▶ Ludzie próbowali nauczyć komputery „myślenia” poprzez używanie symboli i reguł, jak w grze szachowej.
- ▶ Zbudowali „inteligentne” programy, które mogły rozwiązywać łamigłówki i zagadki, używając zasad i instrukcji.
- ▶ Celem było, aby komputer używał tych reguł, aby sam znaleźć odpowiedzi na pytania i rozwiązać problemy.



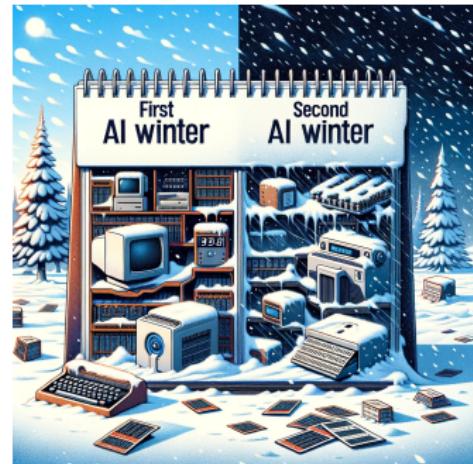
# Wzloty i Upadki AI

## ► Wzloty:

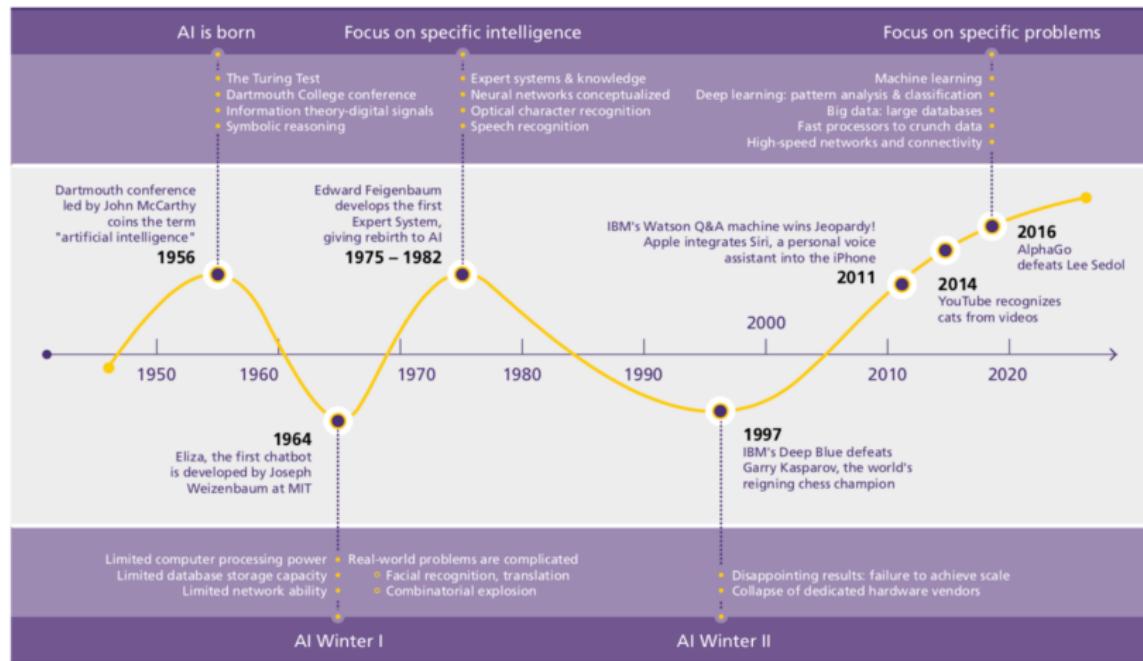
- ▶ Lata 50. i 60.: Dużo optymizmu, pierwsze programy grające w szachy, rozpoznające obrazy.
- ▶ Lata 80.: Boom na ekspertowe systemy komputerowe, które pomagały lekarzom i inżynierom w rozwiązywaniu problemów.

## ► Upadki („Zimy AI”):

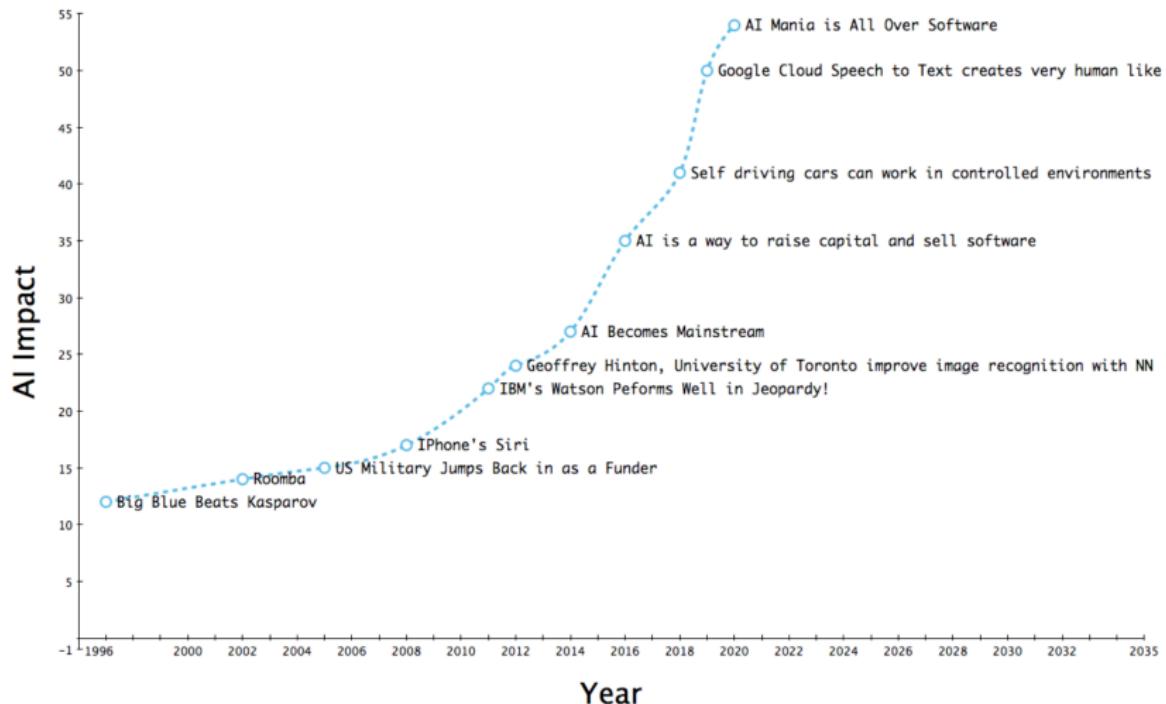
- ▶ Lata 70.: Brak postępów, problemy techniczne, cięcia finansowania.
- ▶ Lata 90.: Konkurencja z innymi technologiami, mniej funduszy na badania.



# Zimy AI



# Eksplozja AI



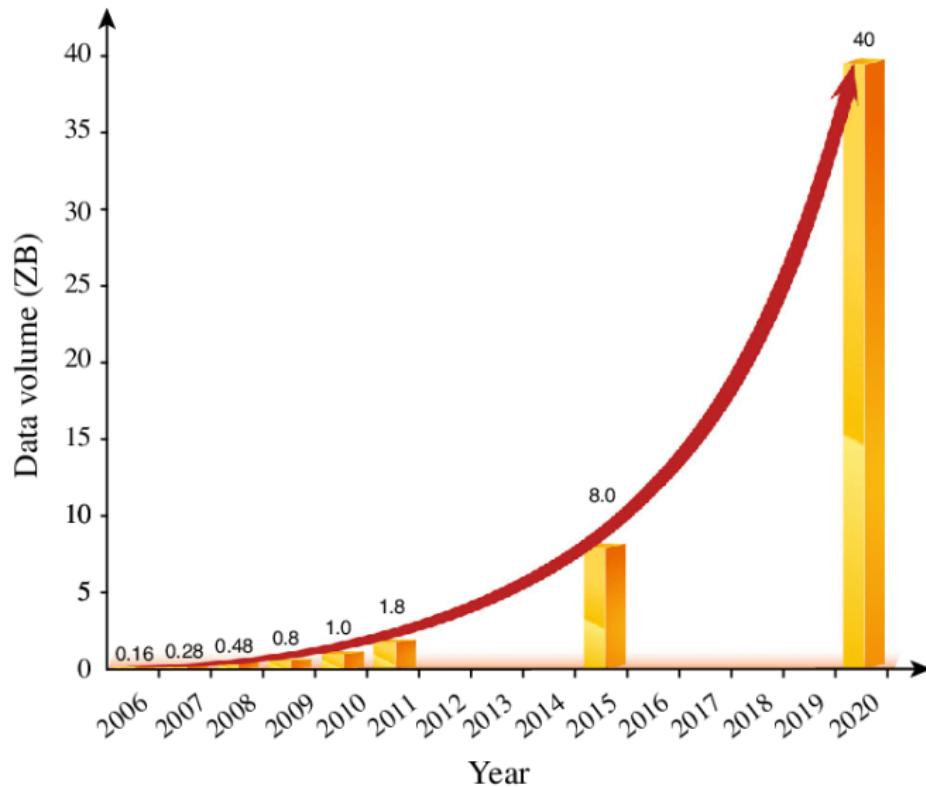
# Co przyczyniło się do eksplozji AI po latach 90?

- ▶ Rozwój i ekspansja internetu
- ▶ Wzrost dostępnych danych cyfrowych
- ▶ Rozwój nowych algorytmów uczenia maszynowego
- ▶ Ulepszenia technologiczne i mocniejsze komputery

# Co przyczyniło się do eksplozji AI po latach 90?

- ✓ Rozwój i ekspansja internetu
- ✓ Wzrost dostępnych danych cyfrowych
- ✓ Rozwój nowych algorytmów uczenia maszynowego
- ✓ Ulepszenia technologiczne i mocniejsze komputery

# Wzrost danych cyfrowych w zetabajtach ( $10^{21}$ )



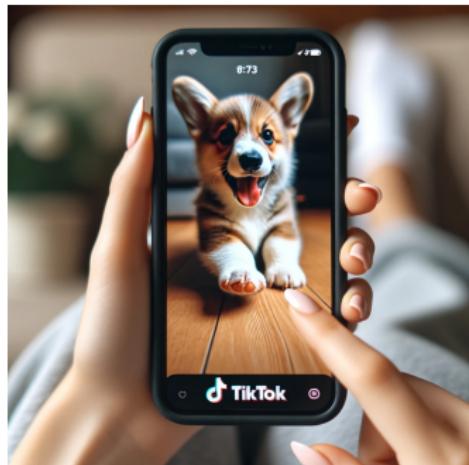
# Eksplozja danych wideo w internecie

- ▶ Co minutę na internet trafia **500 godzin materiału wideo.**
- ▶ Około **11 miliardów TikToków** jest przesyłanych co rok na platformę.



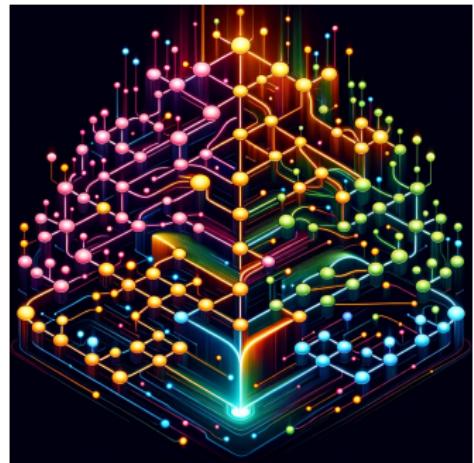
# Ogrom danych na platformie TikTok

- ▶ Każdego dnia dodawanych jest **33 miliony** nowych TikToków,
- ▶ Jeśli każdy TikTok trwa średnio 1 minute
- ▶ **To jednemu człowiekowi zajęłoby ponad 400 lat nieprzerwanego oglądania, aby zobaczyć wszystkie TikToki dodane TYLKO dzisiaj na platformie.**



# Rozwój algorytmów uczenia maszynowego w latach 90.

- ▶ Algorytmy takie jak Support Vector Machines (SVM) i Random Forests zyskały popularność dzięki swojej elastyczności i mocnemu matematycznemu podłożu.
- ▶ Mimo że sieci neuronowe były już znane, ich zastosowanie wymagało zbyt dużego nakładu mocy obliczeniowej.



# Ulepszenia technologiczne i mocniejsze komputery

- ▶ **Karty graficzne (GPU):** Ulepszony hardware graficzny, który okazał się być wyjątkowo efektywny w przyspieszaniu obliczeń wymaganych w algorytmach głębokiego uczenia.
- ▶ **Era Deep Learning:** Rozwój GPU w latach 2000. umożliwił powstanie i szybki rozwój głębokiego uczenia, revolutionizując dziedziny takie jak rozpoznawanie obrazów i przetwarzanie języka naturalnego.



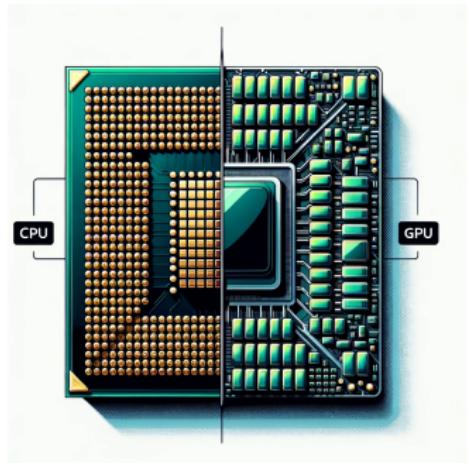
# Karty graficzne (GPU) a głębokie uczenie

## ► CPU:

- ▶ Zoptymalizowany do zarządzania systemem i koordynowania pracy różnych części komputera.
- ▶ Specjalizuje się w zadaniach wymagających trudnych obliczeń.

## ► GPU:

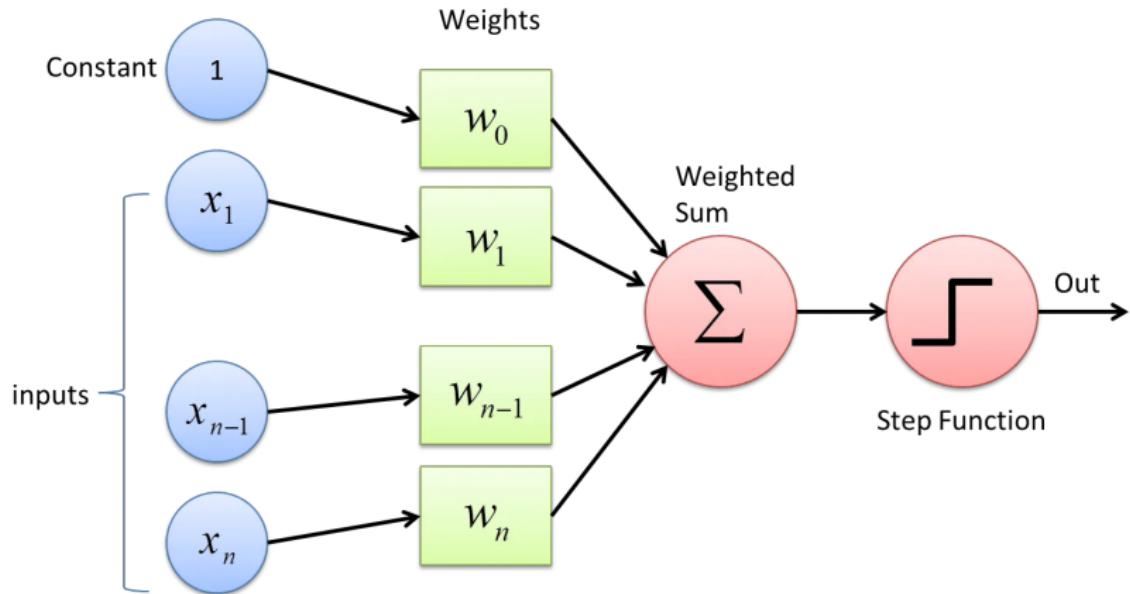
- ▶ Specjalizuje się w wykonywaniu wielu obliczeń matematycznych jednocześnie.
- ▶ Idealny do zadań związanych z głębokim uczeniem, które wymagają dużej ilości prostych operacji matematycznych.



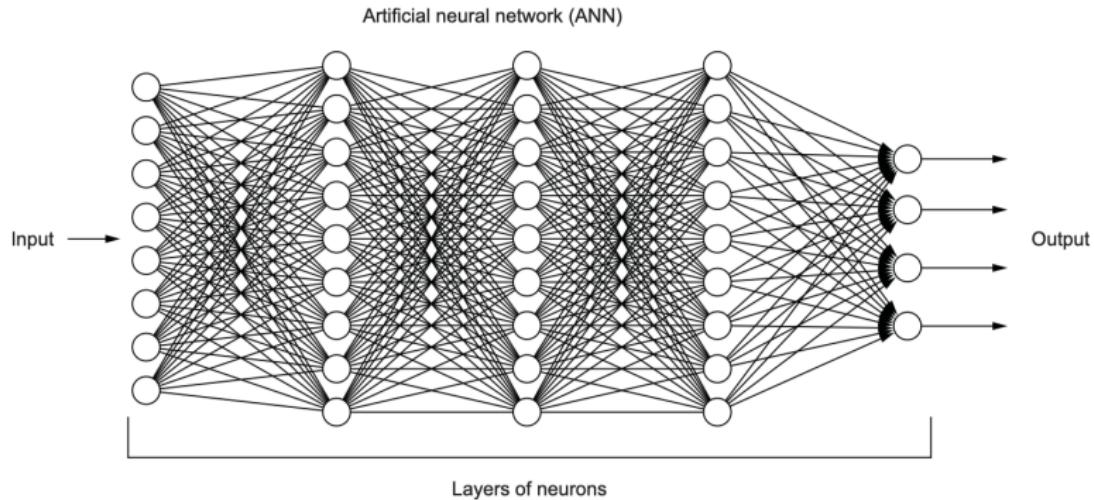
# GPU: Klucz do przejścia od Machine Learning do Deep Learning

- ▶ **Proste operacje:** Głębokie uczenie, zwłaszcza sieci neuronowe, polega głównie na prostych operacjach matematycznych takich jak dodawanie i mnożenie.
- ▶ **Więcej rdzeni w GPU:** Karty graficzne mają znacznie więcej rdzeni niż procesory CPU. Na przykład, nowoczesne GPU mogą mieć nawet 5000 rdzeni, podczas gdy typowe CPU może mieć do 32 rdzeni.
- ▶ **Wpływ na Deep Learning:** Wykorzystanie GPU umożliwiło naukowcom trenowanie głębokich i złożonych modeli, co było trudne do osiągnięcia przy użyciu tylko CPU.

# Perceptron

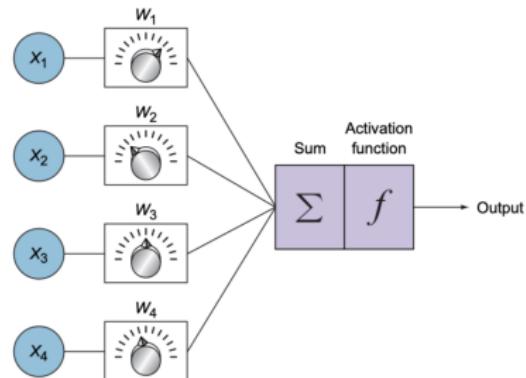


# Sieć Neuronowa (wiele perceptronów)

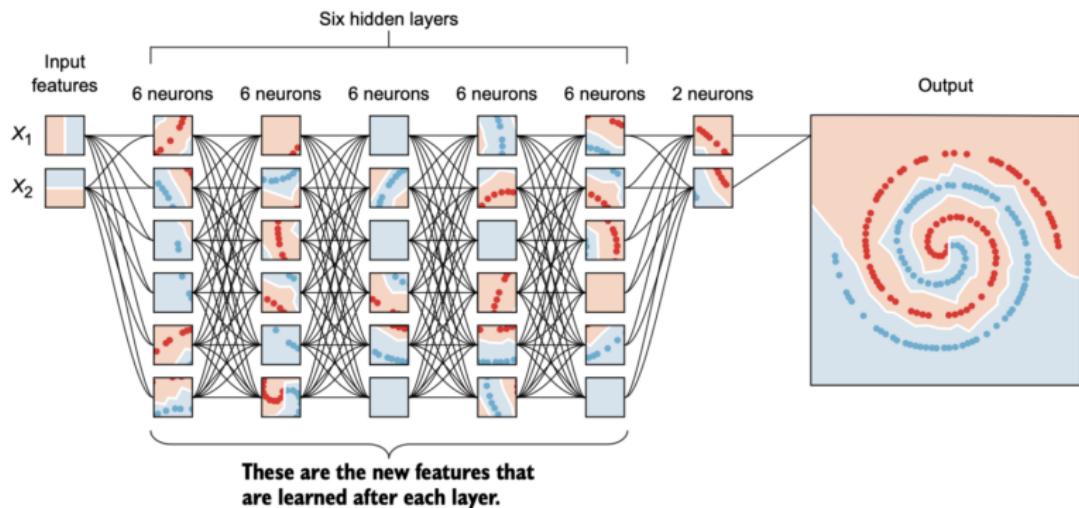


# Jak działają sieci neuronowe?

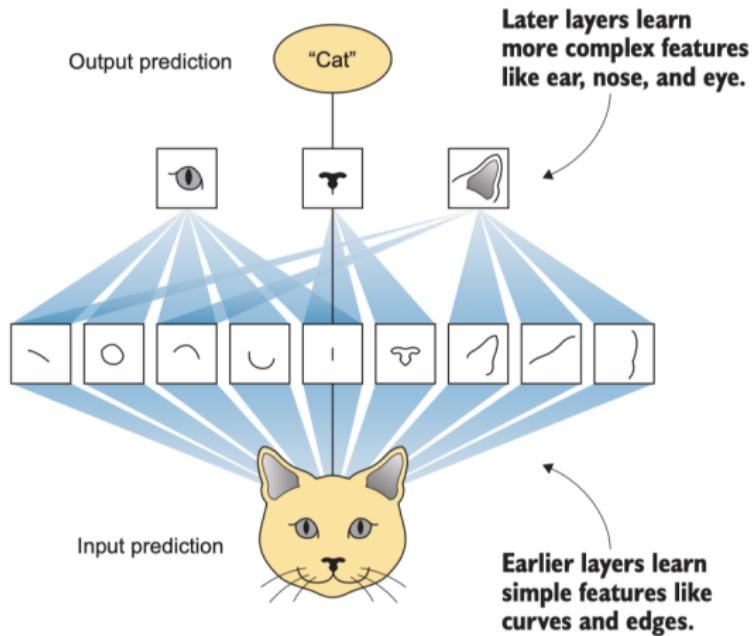
- ▶ Sieci neuronowe używają "neuronów" połączonych "wagami", które działają jak przełączniki.
- ▶ Wagi "sterują" tym, jak silny jest wpływ jednego neuronu na drugi.
- ▶ Sieć "uczy się" poprzez dostosowywanie tych wag, tak aby lepiej przewidywać odpowiedzi na podstawie danych wejściowych.



# Sieć Neuronowa (wiele perceptronów)



# Cechy (features)



# Agenda

1. Historia i rozwój AI
2. **Przerwa**
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. QA - Sesja pytań i odpowiedzi

# Agenda

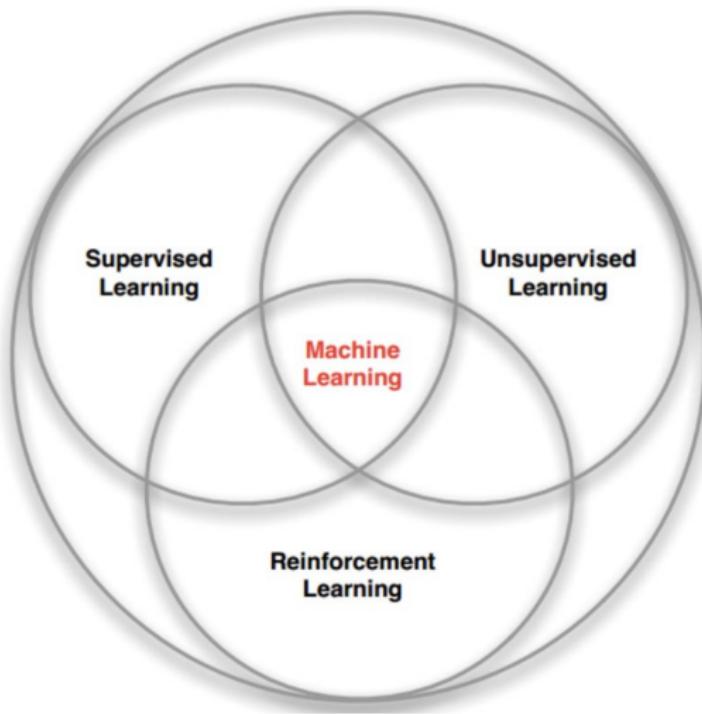
1. Historia i rozwój AI
2. Przerwa
3. **Podstawy uczenia maszynowego i uczenia głębokiego**
4. QA - Sesja pytań i odpowiedzi

# Co to jest uczenie maszynowe?

- ▶ Uczenie maszynowe to sposób, aby komputery uczyły się od danych.
- ▶ Komputery mogą uczyć się rozpoznawać wzorce, podejmować decyzje i przewidywać przyszłe wydarzenia.
- ▶ Przykłady: Filtrowanie spamu w e-mailach, rekomendacje filmów, prognozowanie pogody.



# Typy uczenia maszynowego



# Typy uczenia maszynowego

- ▶ **Uczenie nadzorowane (Supervised Learning):** Model uczy się na podstawie **oznaczonych danych** i przewiduje wyniki na podstawie nowych danych. Przykłady to regresja i klasyfikacja.
- ▶ **Uczenie nienadzorowane (Unsupervised Learning):** Model uczy się wykrywać wzorce w danych, które nie są oznaczone. Przykłady to klasteryzacja i redukcja wymiarowości.
- ▶ **Uczenie przez wzmacnianie (Reinforcement Learning):** Model uczy się podejmować decyzje, wykonując akcje w środowisku, aby uzyskać jak największą nagrodę. ❤

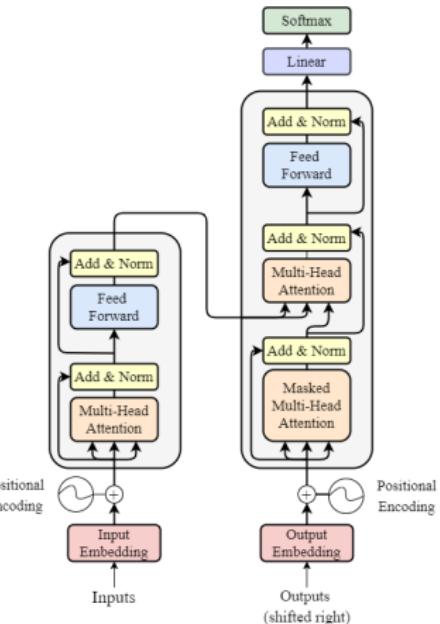
# Co to jest głębokie uczenie?

- ▶ Głębokie uczenie to część uczenia maszynowego oparta na **sieciach neuronowych**
- ▶ Umożliwia komputerom naukę z dużych ilości danych.
- ▶ Przykłady: Rozpoznawanie obrazów, generowanie tekstu, tłumaczenie języków.

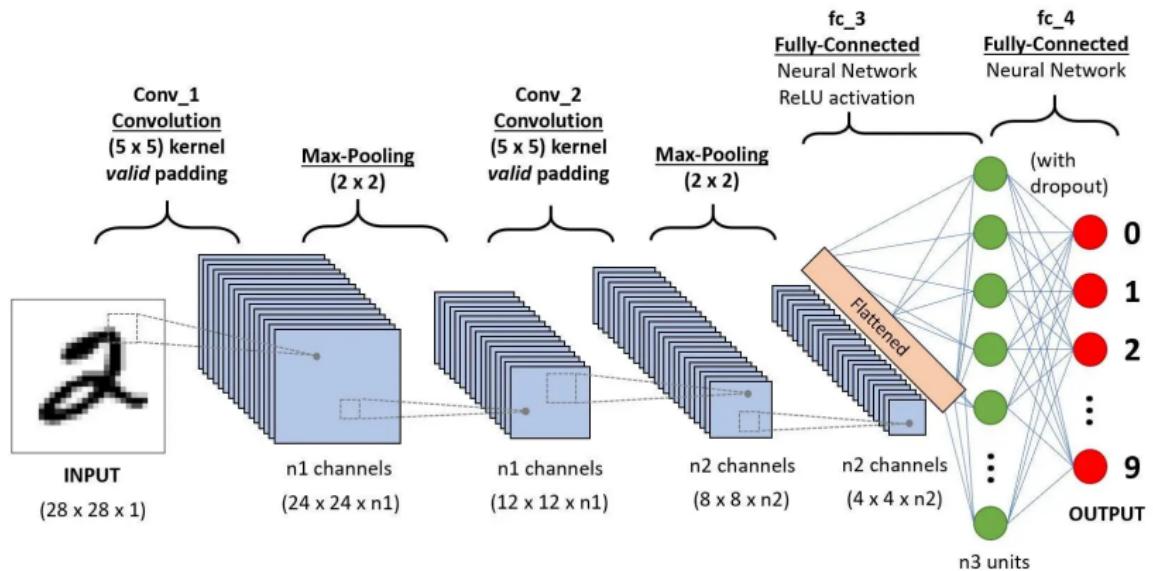


# Czy sieci neuronowe są naprawdę tak potężne?

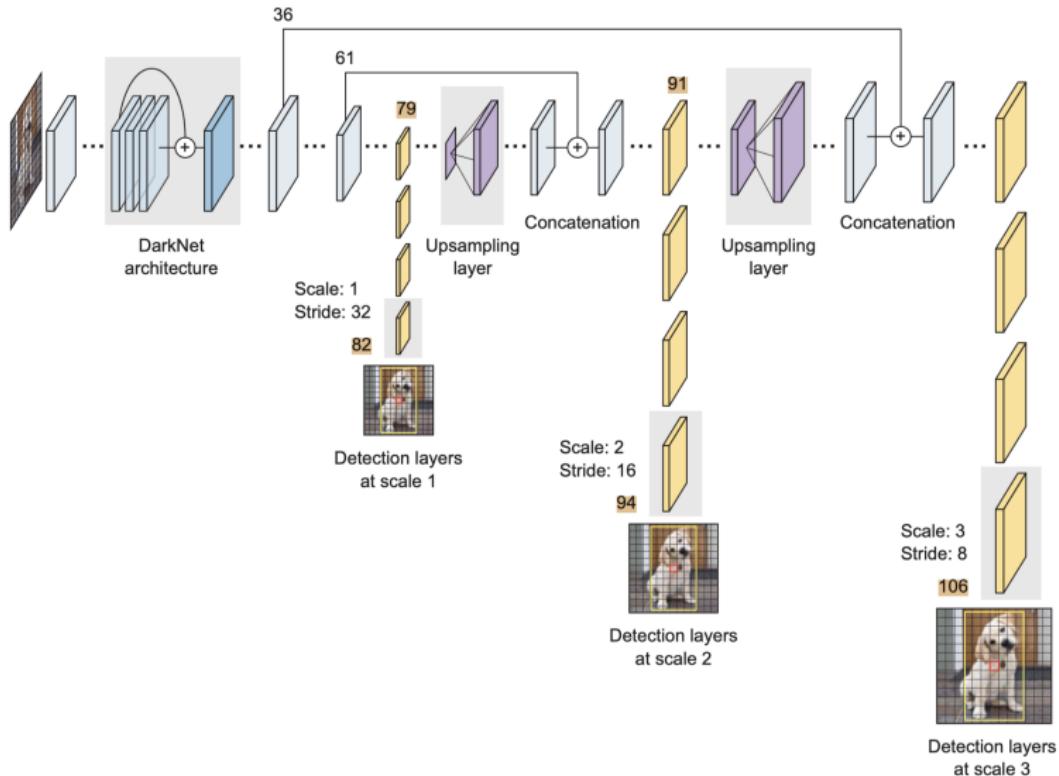
- ▶ Sieci neuronowe to potężne narzędzia, ale same w sobie **nie są "magiczne"**.  
To sposób, w jaki są używane w różnych architekturach i modelach, sprawia, że są skuteczne.
- ▶ Często słyszymy, że "sieci neuronowe osiągnęły coś niesamowitego", ale prawda jest taka, że to **złożone modele i algorytmy, które wykorzystują sieci neuronowe**, osiągają te wyniki.



# Convolutional Neural Network



# You Only Look Once (YOLO)



# Jak działa uczenie nadzorowane?

# Nauczyciel w świecie maszyn: Uczenie Nadzorowane

- ▶ **Nauczyciel:** W uczeniu nadzorowanym, "nauczyciel" (człowiek) pokazuje komputerowi, co ma się nauczyć, podając **przykłady danych i odpowiednich etykiet**.
- ▶ **Książka z odpowiedziami:** Podobnie jak w szkolnej książce z odpowiedziami, komputer otrzymuje zestaw pytań **wraz z odpowiedziami (etykiety)**, które pomagają mu się uczyć.



# Problemy rozwiązywane przez uczenie nadzorowane

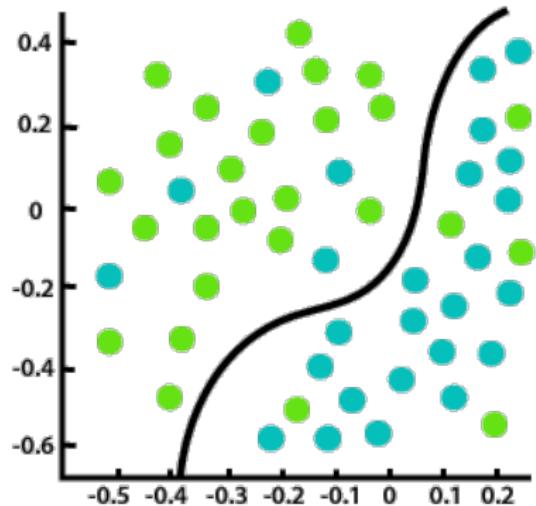
## ► Regresja:

- ▶ Przewidywanie ciągłych wartości.
- ▶ Przykład: Estymacja ceny mieszkania na podstawie jego lokalizacji, rozmiaru i cech.

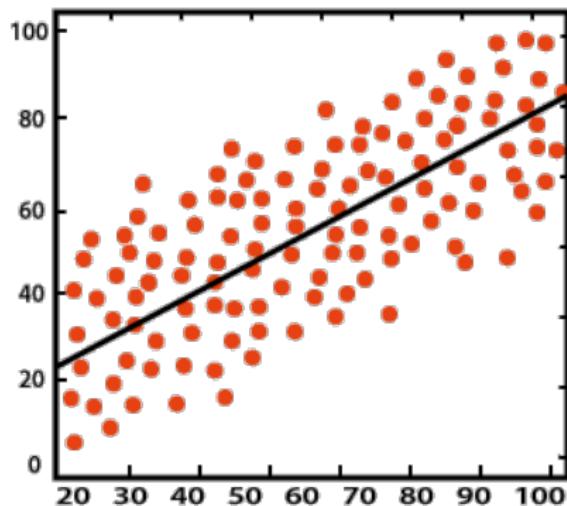
## ► Klasifikacja:

- ▶ Przewidywanie dyskretnych etykiet.
- ▶ Przykład: Rozpoznawanie kotków i piesków na zdjęciach.

# Klasyfikacja oraz regresja



Classification



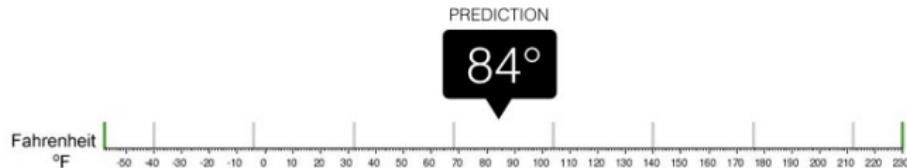
Regression

# Klasyfikacja oraz regresja



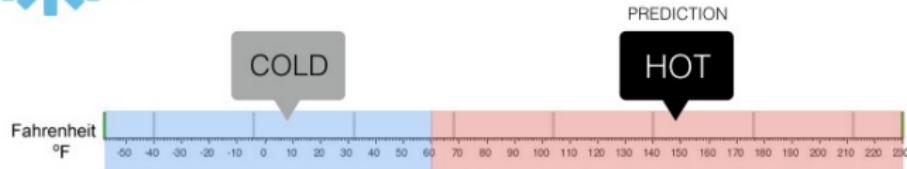
## Regression

What is the temperature going to be tomorrow?



## Classification

Will it be Cold or Hot tomorrow?



# Czym są dane oznaczone ?

- ▶ **Oznaczone odpowiedziami:** Dane oznaczone zawierają informacje wejściowe oraz odpowiadające im etykiety, które służą jako odpowiedzi.
- ▶ **Podstawa uczenia nadzorowanego:** Dzięki etykietom, model uczenia maszynowego może nauczyć się rozpoznawać wzorce i dokonywać przewidywań.

# Dane označzone

Labeled data



Dog



Dog

Labeled data



18 pounds



14 pounds

Unlabeled data



Cat



Cat



12 pounds

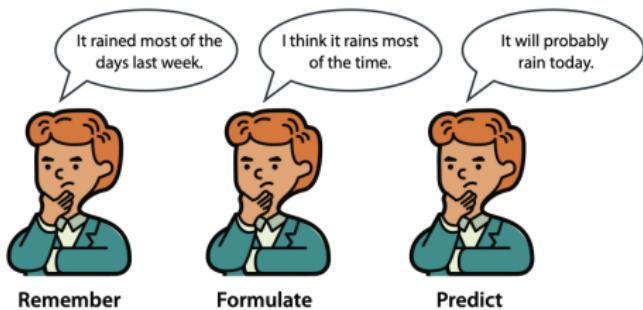


9 pounds

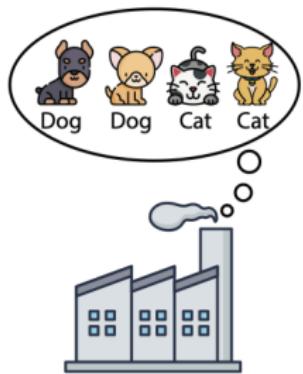


# Jak działa uczenie nadzorowane?

- ▶ **Zapamiętanie:** Model uczy się na podstawie danych historycznych, które są "oznaczone" odpowiedziami.
- ▶ **Formułowanie:** Na podstawie tych danych, model "formułuje" zależności i wzorce.
- ▶ **Predykcja:** Używając nauczonych wzorców, model jest w stanie przewidywać przyszłe zdarzenia.



# Klasyfikator piesków i kotków



**Remember**

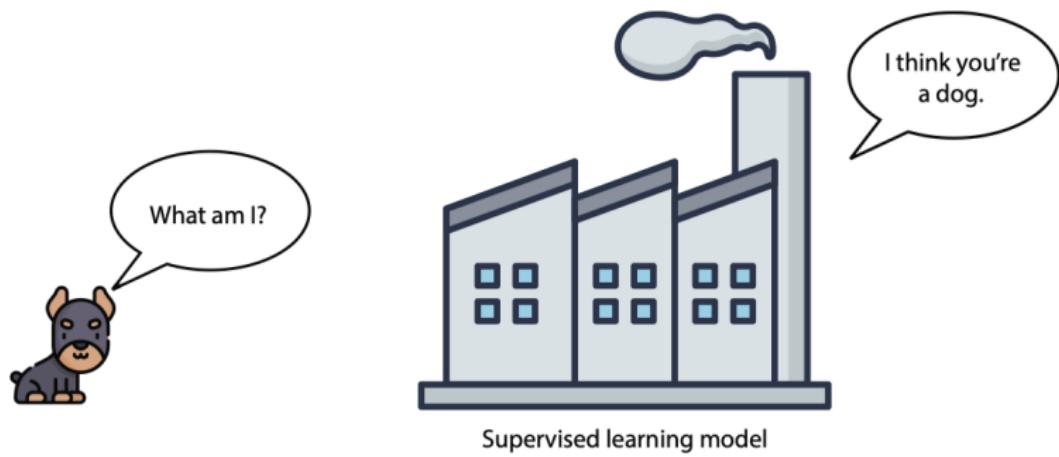


**Formulate**



**Predict**

# Klasyfikator piesków i kotków



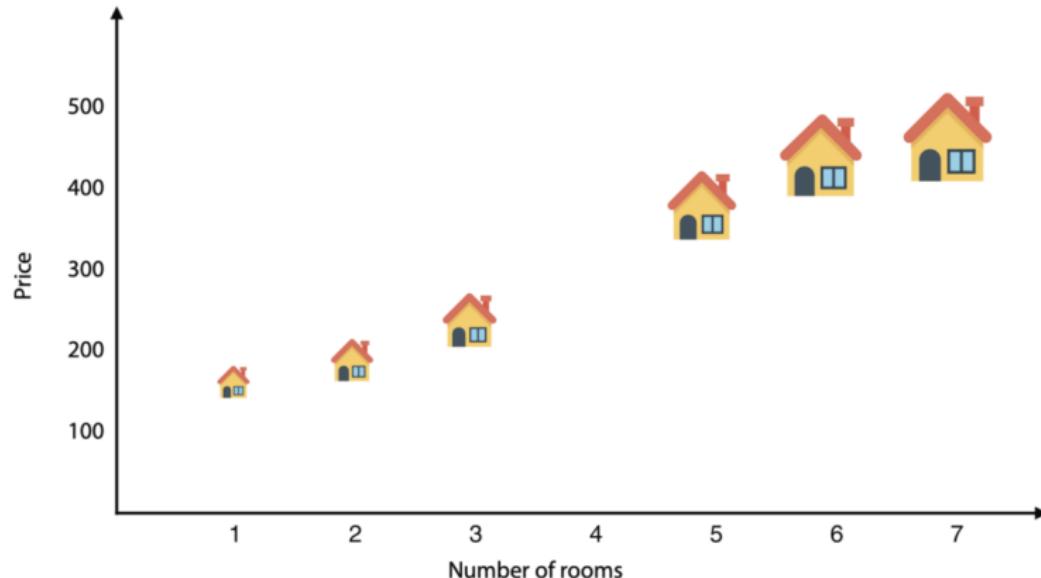
# Regresja ceny mieszkań (R-F-P)



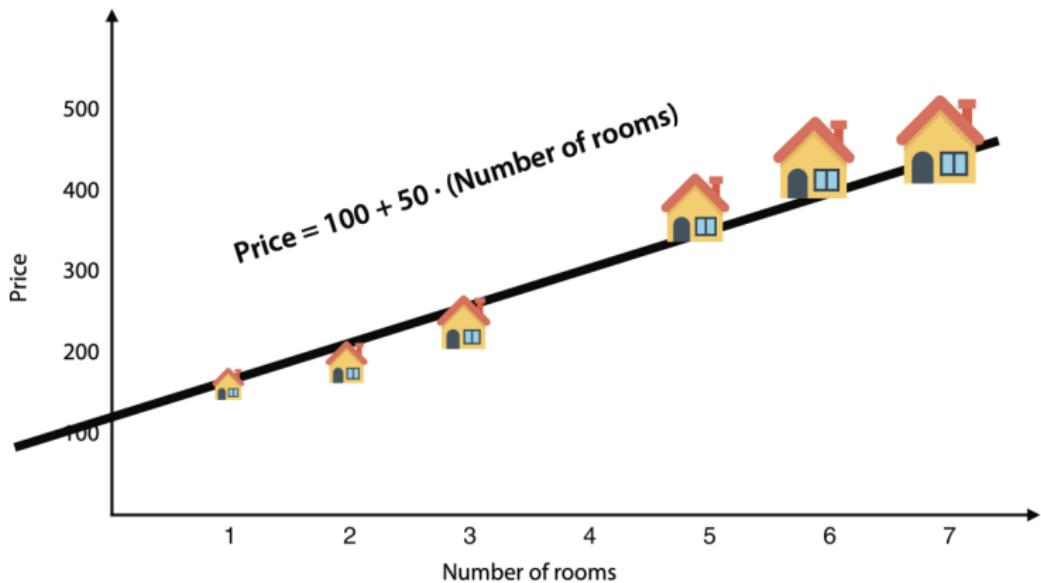
## Cena mieszkania w.r.t ilości pokoi

Number of rooms	Price
1	150
2	200
3	250
4	?
5	350
6	400
7	450

## Step 1. R-remember (Zapamiętywanie danych oraz etykiet)



## Step 2. F-formulate (Formułowanie Zasad)



## Cena mieszkania w.r.t ilości pokoi

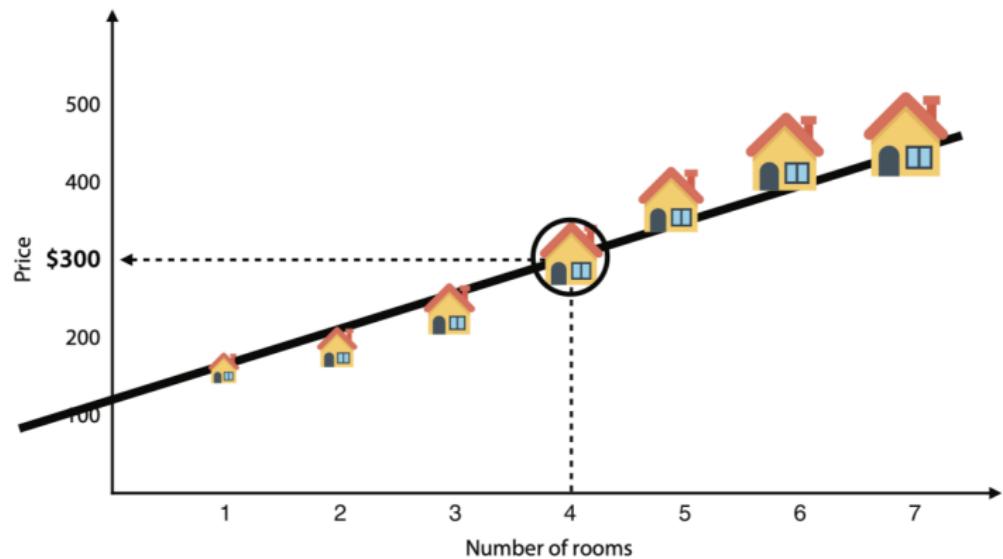
Number of rooms	Price
1	155
2	197
3	244
4	?
5	356
6	407
7	448

## Step 3. P-redict (Predykcja etykiet których nie znamy)

Number of rooms	Price
1	155
2	197
3	244
4	?
5	356
6	407
7	448

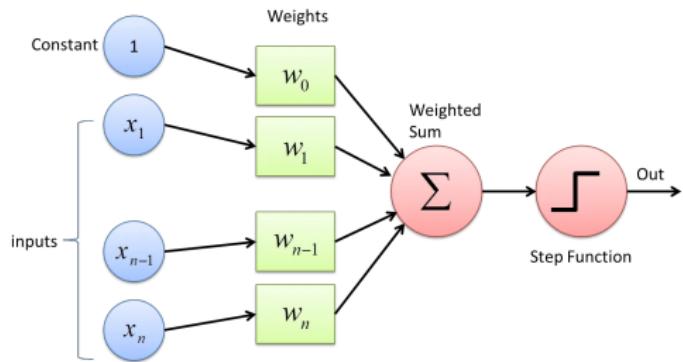


### Step 3. P-redict (Predykcja etykiet których nie znamy)

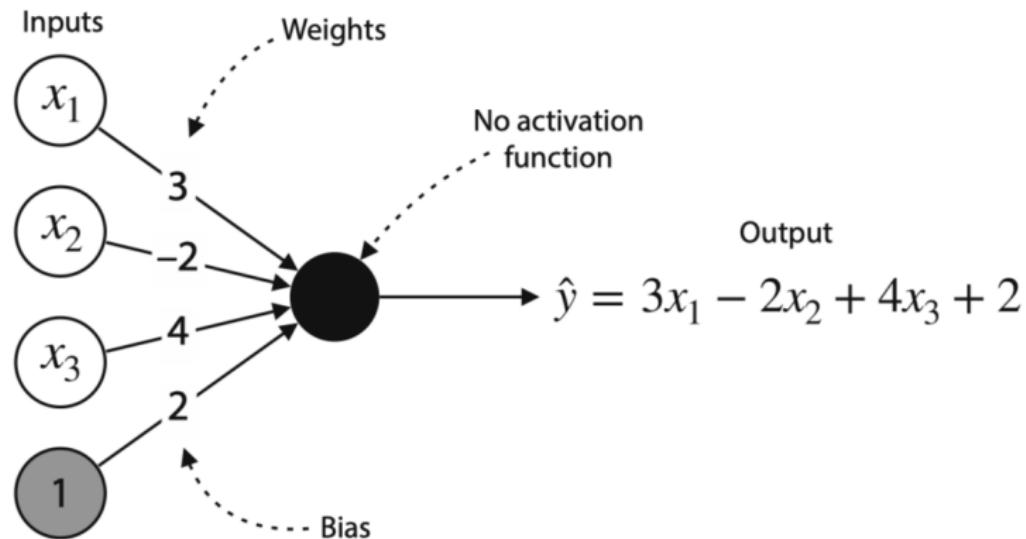


# Perceptron: równanie liniowe i funkcja aktywacji

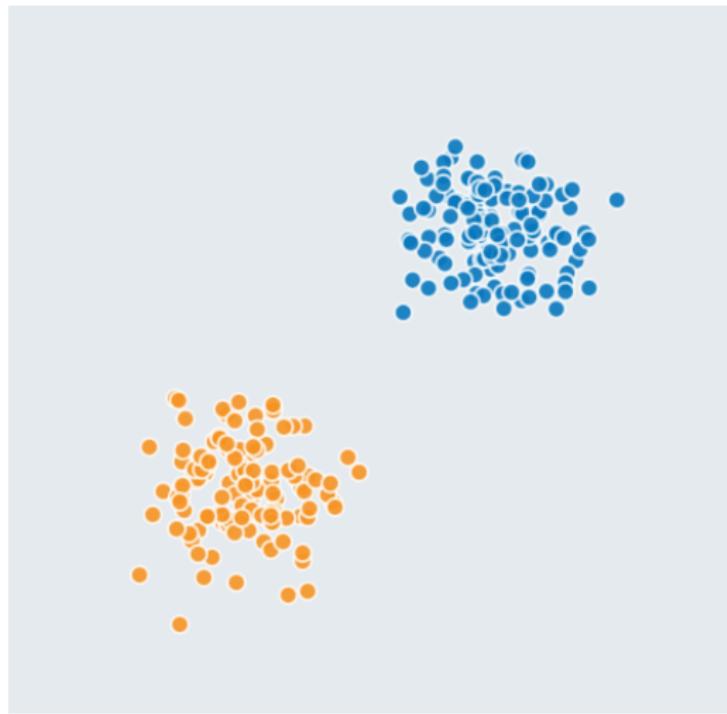
- ▶ Perceptron Składa się z **równania liniowego**, które sumuje wejścia pomnożone przez ich wagi,
- ▶  $\sum_{i=1}^n w_i x_i + b$
- ▶ gdzie  $w_i$  to waga  $i$ -tego wejścia  $x_i$ , a  $b$  to wyraz wolny (bias).



# Równanie bez aktywacji



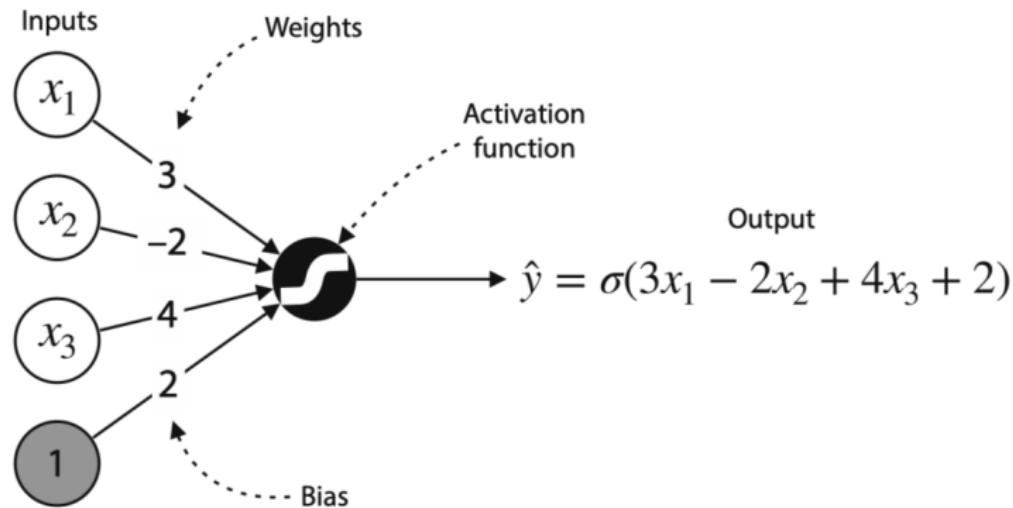
## Dane które można separować liniowo



Funkcja liniowa to za mało

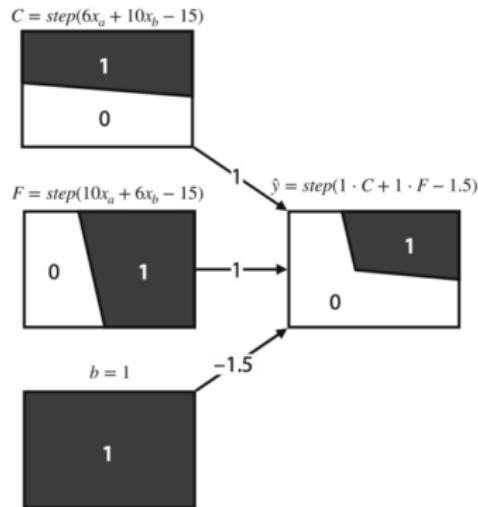


# Równanie z aktywacją

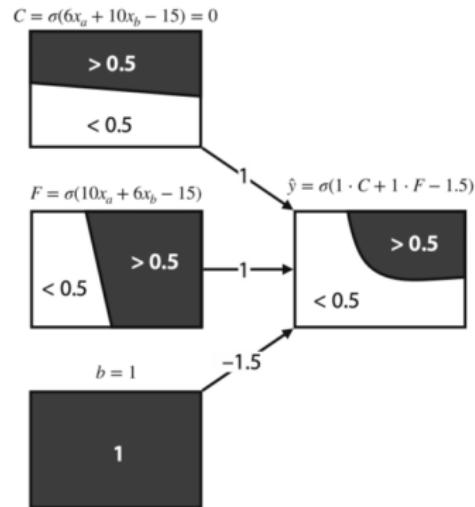


# Przewaga aktywacji

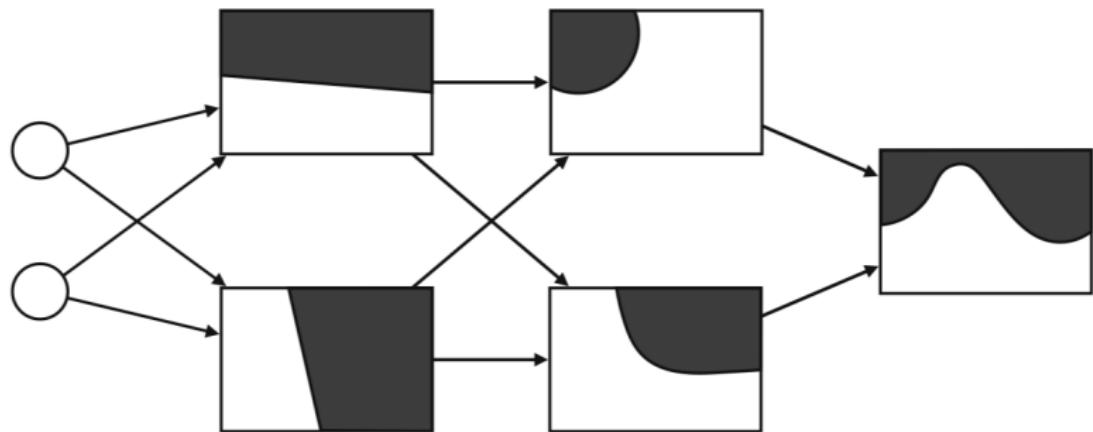
With the step activation function



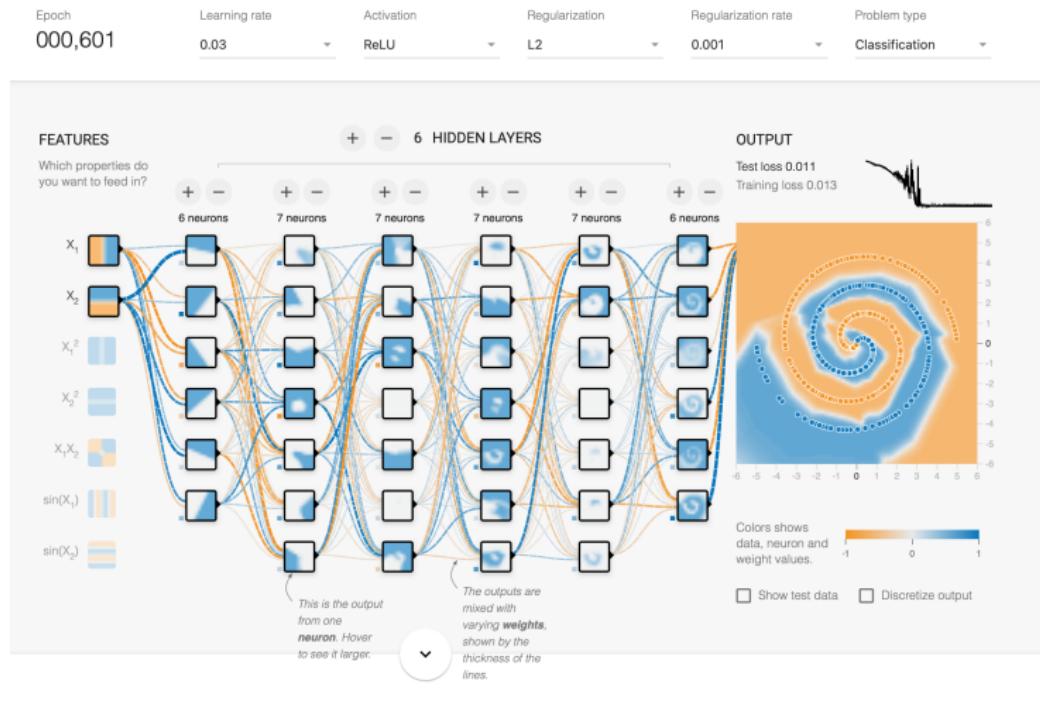
With the sigmoid activation function



# Nieliniowe wzorce



# Sieć neuronowa z aktywacją

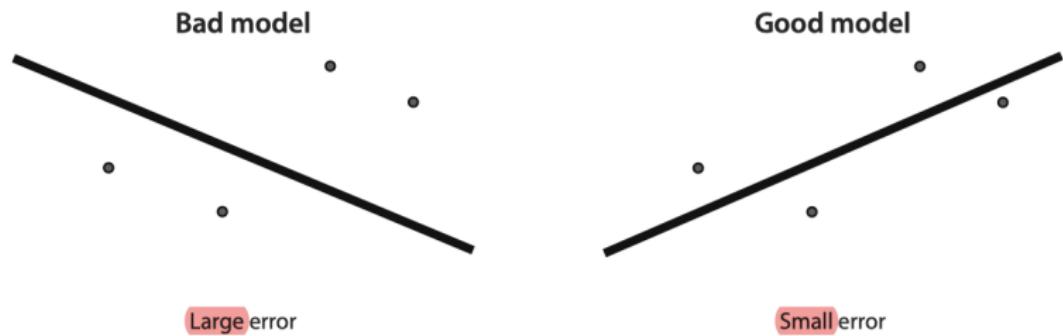


Co w przypadku gdy model się  
pomyli?

# Uczenie modelu poprawnego zachowania

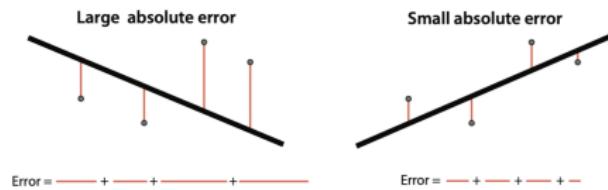


# Dobre oraz złe zachowanie - regresja ceny mieszkań



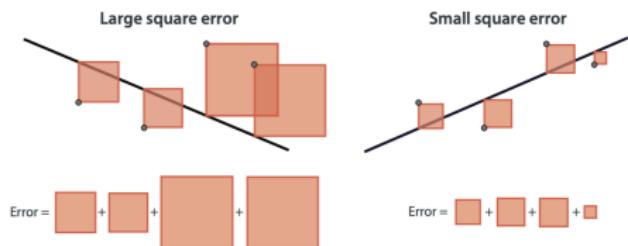
# Funkcja straty L1 (MAE)

- ▶ **Definicja:** L1, czyli błąd bezwzględny średni (MAE),
- ▶ mierzy średnią wartość bezwzględnych różnic między przewidywaniami a rzeczywistymi wartościami.

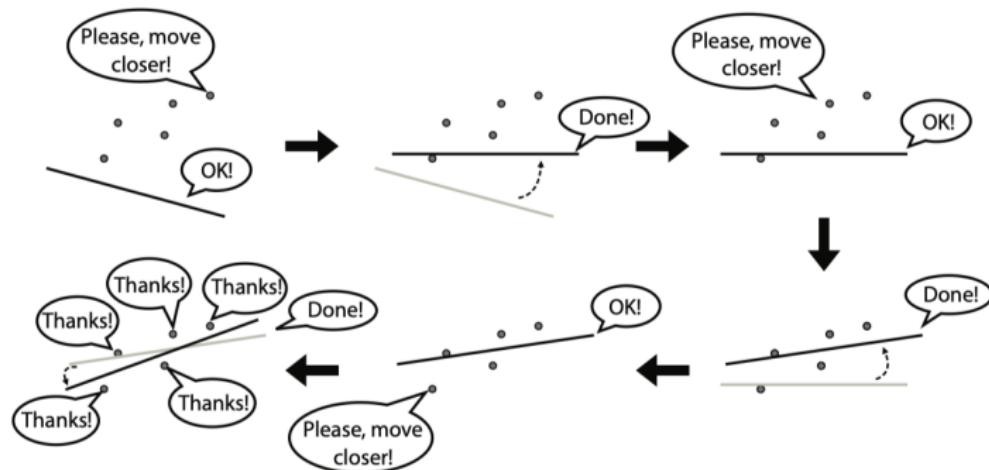


# Funkcja straty L2 (MSE)

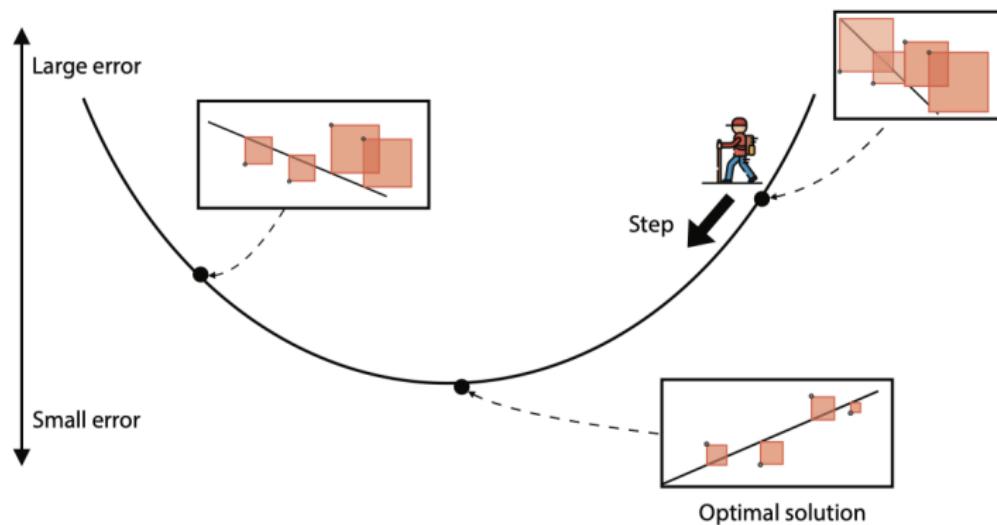
- ▶ **Definicja:** L2, czyli błąd średniokwadratowy (MSE),
- ▶ mierzy średnią wartość kwadratów różnic między przewidywaniami a rzeczywistymi wartościami.



# Co mówi błąd do modelu



# Minimalizacja błędu



## Podsumowanie: Uczenie maszynowe i jego aspekty

- ▶ Uczenie maszynowe to dziedzina sztucznej inteligencji skoncentrowana na rozwijaniu algorytmów, które mogą uczyć się z danych i dokonywać prognoz lub decyzji bez jawnego programowania.
- ▶ Uczenie nadzorowane, jedna z głównych kategorii uczenia maszynowego, zajmuje się problemami regresji i klasyfikacji poprzez analizowanie danych etykietowanych.
- ▶ Sieci neuronowe wykorzystują funkcje aktywacji do wprowadzania nieliniowości w procesie uczenia, co pozwala na modelowanie skomplikowanych wzorców w danych.

# Agenda

1. Historia i rozwój AI
2. Przerwa
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. **QA - Sesja pytań i odpowiedzi**