

Cyfrowa Rewolucja

Jakub Chojnacki

November 6, 2023

O autorze



IBE  INSTYTUT
BADAN
EDUKACYJNYCH

 Billennium

Kontakt

- ▶ **Imię i Nazwisko:** Jakub Chojnacki
- ▶ **E-mail:** james@marl.engineering
- ▶ **Strona internetowa:**
<https://www.marl.engineering>
- ▶ **Repozytorium**
<https://github.com/Sithael>

James Chojnacki

Reinforcing Understanding



I am deeply passionate about the **brain** and **multi-agent systems**, believing strongly that intelligence is shaped by the environment, and our human environment, in essence, is multi-agent. As an avid researcher in these fields, my work centers around exploring and understanding these complex systems and their impacts on intelligence growth and development.

Organizacja kursu

- ▶ **Logowanie ALS** Zapoznanie z instrukcją logowania do ALS
- ▶ **Konto OpenAI** Założone konto na portalu OpenAI
- ▶ **Link do laboratorium** Zostanie udostępniony na chat przez prowadzącego

Agenda

1. Historia i rozwój AI
2. Przerwa
3. Podstawy maszynowego uczenia i głębokiego uczenia
4. QA - Sesja pytań i odpowiedzi

Agenda

1. **Historia i rozwój AI**
2. Przerwa
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. QA - Sesja pytań i odpowiedzi

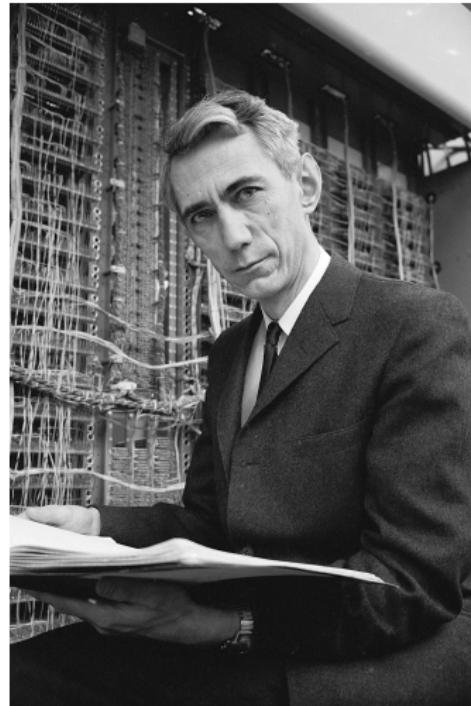
Definicja AI

- ▶ Sztuczna inteligencja to dziedzina nauki komputerowej.
- ▶ Uczy maszyny "myśleć" i podejmować decyzje jak ludzie.
- ▶ Dzięki AI, komputery mogą:
 - ▶ Rozpoznawać obrazy.
 - ▶ Rozumieć język ludzi.
 - ▶ Grać w gry.



Początki myśli o AI

- ▶ **Alan Turing (1940s):**
 - ▶ "Maszyna Turinga" - podstawy teoretyczne dla komputerów.
 - ▶ Test Turinga - koncepcja oceny inteligencji maszynowej.
- ▶ **Claude Shannon (1940s-50s):**
 - ▶ Twórca teorii informacji.
 - ▶ Badania nad algorytmami genetycznymi i uczeniem maszynowym.
- ▶ **John McCarthy (1950s):**
 - ▶ Wprowadzenie terminu "sztuczna inteligencja".
 - ▶ Twórca języka programowania Lisp, popularnego w badaniach nad AI.



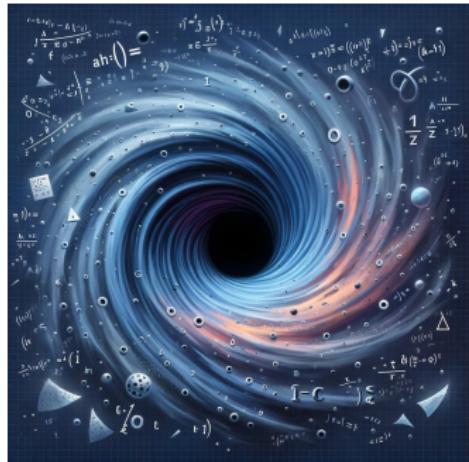
Test Turinga

- ▶ **Zaproponowany przez Alana Turinga w 1950 r. w artykule "Computing Machinery and Intelligence".**
- ▶ **Pytanie kluczowe:** "Czy maszyny mogą myśleć?"
- ▶ Test polega na **konwersacji** między człowiekiem a maszyną ukrytą za ścianą.
- ▶ Jeśli człowiek **nie jest w stanie rozróżnić**, czy rozmawia z maszyną czy innym człowiekiem, maszyna "przechodzi" test.



Claude Shannon i Teoria Informacji

- ▶ Entropia jest miarą niepewności lub "zaskoczenia" zawartego w danym źródle informacji.
- ▶ Wysoka entropia oznacza, że informacje są bardziej chaotyczne, nieprzewidywalne lub mają większą zawartość informacji.
- ▶ Shannon użył entropii do określenia teoretycznych limitów, jak skutecznie można kodować i przesyłać informacje.



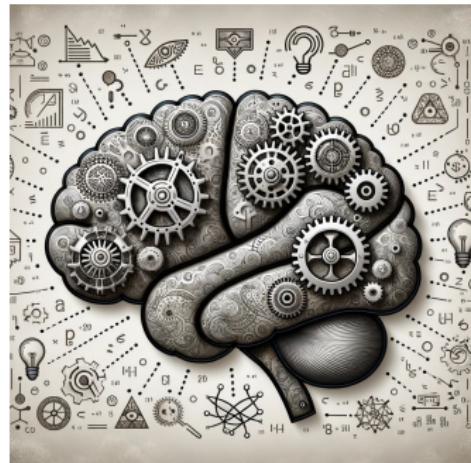
John McCarthy i LISP

- ▶ McCarthy wymyślił słowo "sztuczna inteligencja" w 1955 roku.
- ▶ W 1958 roku stworzył język programowania LISP, który stał się popularny w tworzeniu oprogramowania AI.
- ▶ LISP pozwalał programistom łatwo manipulować symbolami i listami, co było nowością.
- ▶ McCarthy użył LISP-a do budowania programów, które mogły rozwiązywać problemy matematyczne i logiczne.



Era Symboliki w AI

- ▶ To były początki AI, głównie lata 50., 60. i 70. XX wieku.
- ▶ Ludzie próbowali nauczyć komputery „myślenia” poprzez używanie symboli i reguł, jak w grze szachowej.
- ▶ Zbudowali „inteligentne” programy, które mogły rozwiązywać łamigłówki i zagadki, używając zasad i instrukcji.
- ▶ Celem było, aby komputer używał tych reguł, aby sam znaleźć odpowiedzi na pytania i rozwiązać problemy.



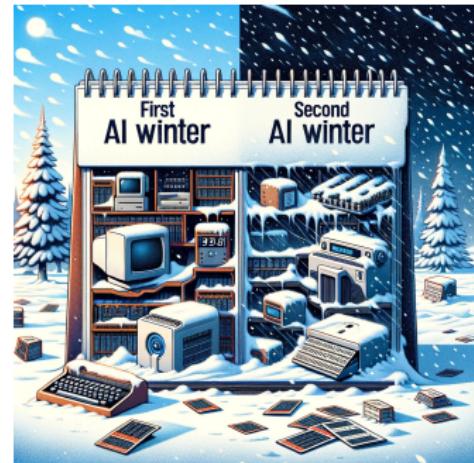
Wzloty i Upadki AI

► Wzloty:

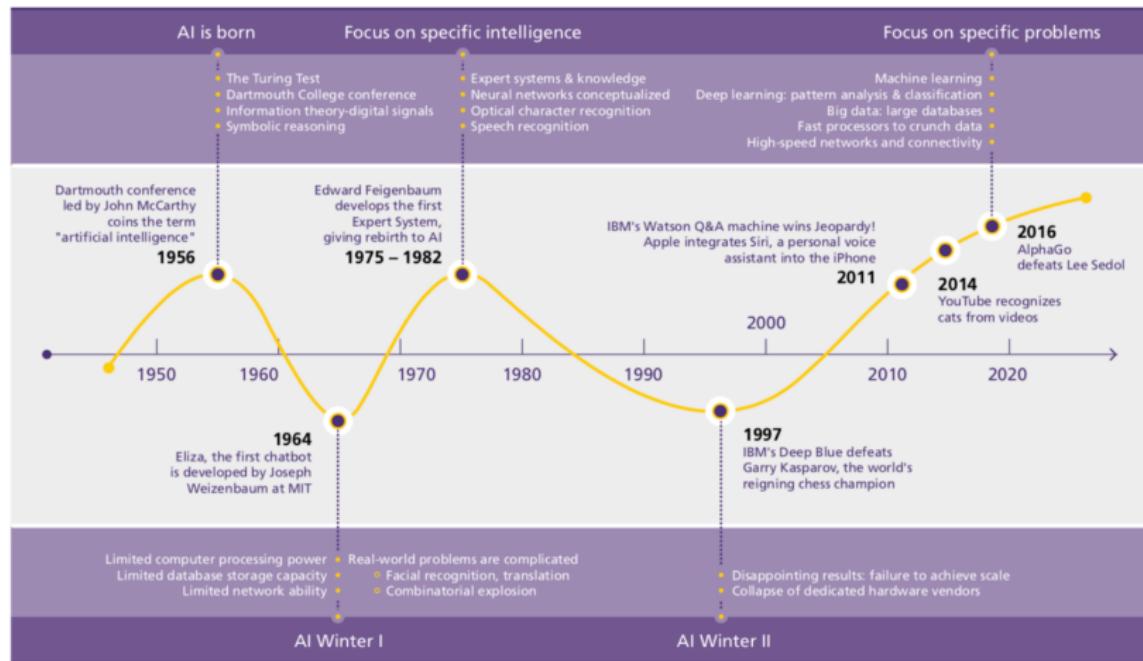
- ▶ Lata 50. i 60.: Dużo optymizmu, pierwsze programy grające w szachy, rozpoznające obrazy.
- ▶ Lata 80.: Boom na ekspertowe systemy komputerowe, które pomagały lekarzom i inżynierom w rozwiązywaniu problemów.

► Upadki („Zimy AI”):

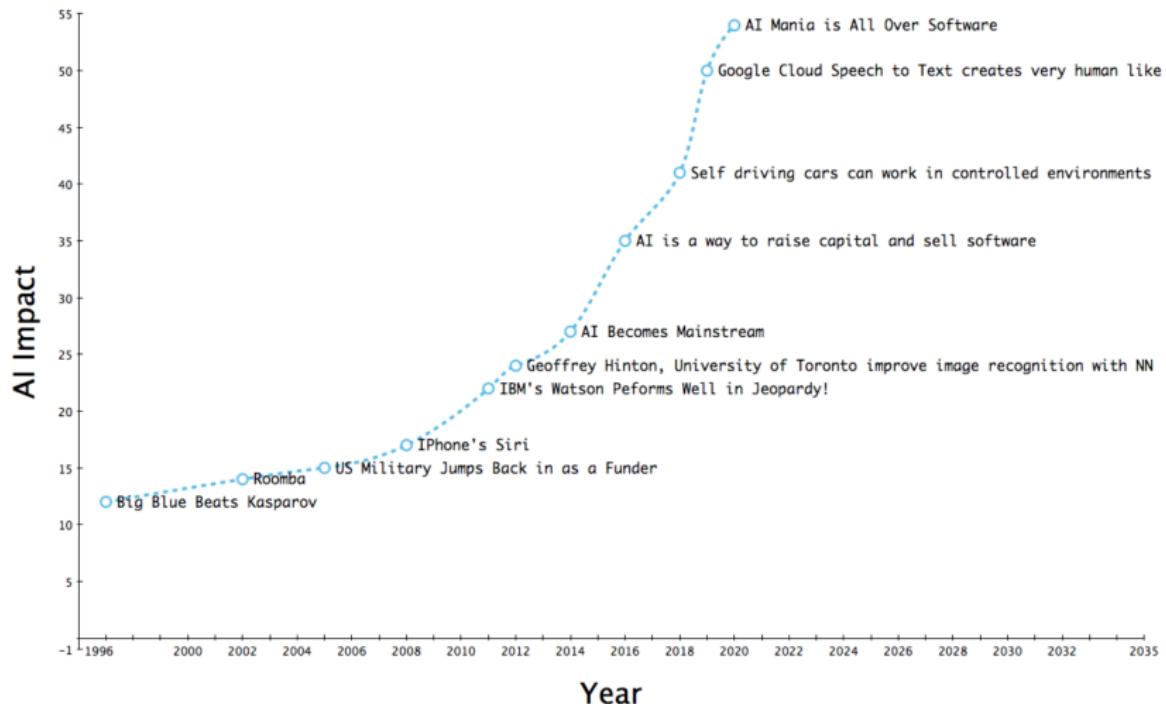
- ▶ Lata 70.: Brak postępów, problemy techniczne, cięcia finansowania.
- ▶ Lata 90.: Konkurencja z innymi technologiami, mniej funduszy na badania.



Zimy AI



Eksplozja AI



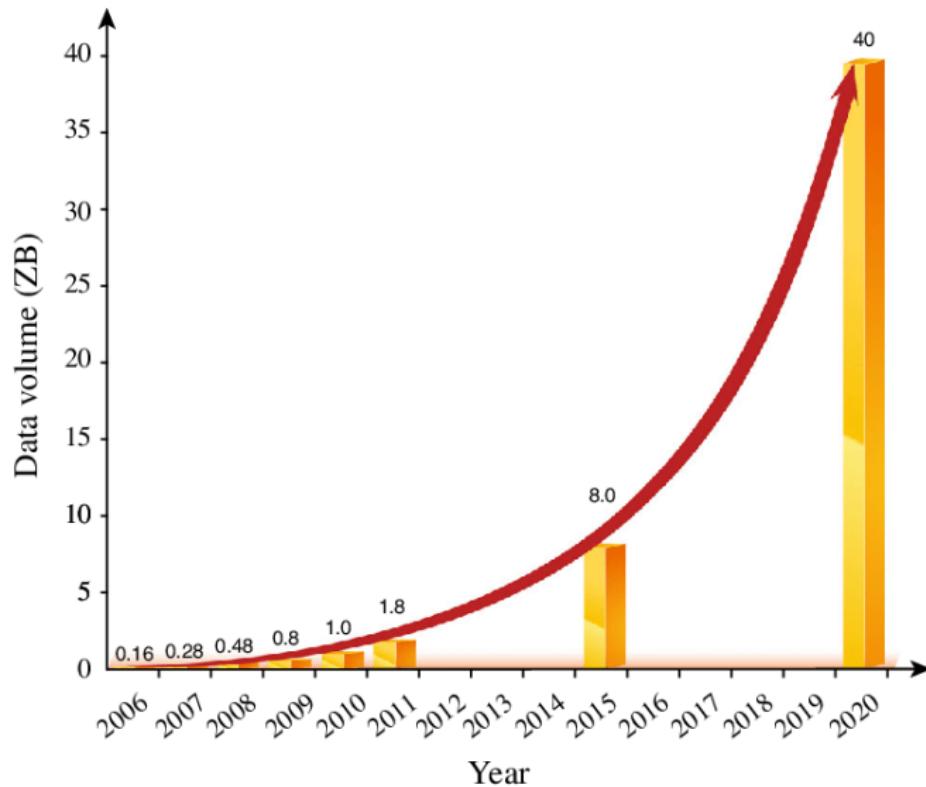
Co przyczyniło się do eksplozji AI po latach 90?

- ▶ Rozwój i ekspansja internetu
- ▶ Wzrost dostępnych danych cyfrowych
- ▶ Rozwój nowych algorytmów uczenia maszynowego
- ▶ Ulepszenia technologiczne i mocniejsze komputery

Co przyczyniło się do eksplozji AI po latach 90?

- ✓ Rozwój i ekspansja internetu
- ✓ Wzrost dostępnych danych cyfrowych
- ✓ Rozwój nowych algorytmów uczenia maszynowego
- ✓ Ulepszenia technologiczne i mocniejsze komputery

Wzrost danych cyfrowych w zetabajtach (10^{21})



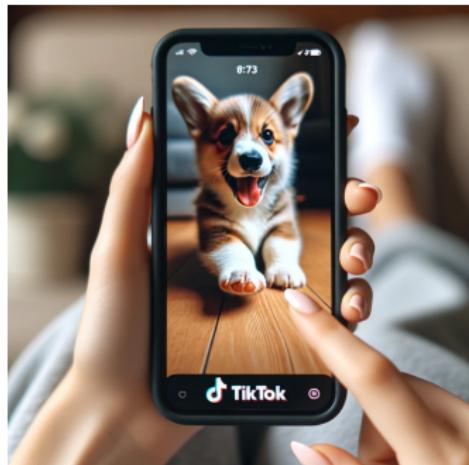
Eksplozja danych wideo w internecie

- ▶ Co minutę na internet trafia **500 godzin materiału wideo.**
- ▶ Około **11 miliardów TikToków** jest przesyłanych co rok na platformę.



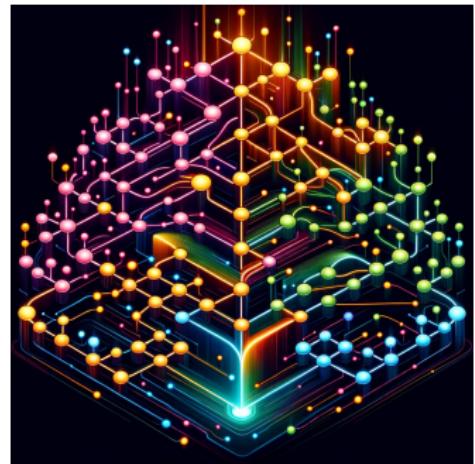
Ogrom danych na platformie TikTok

- ▶ Każdego dnia dodawanych jest **33 miliony** nowych TikToków,
- ▶ Jeśli każdy TikTok trwa średnio 1 minute
- ▶ **To jednemu człowiekowi zajęłoby ponad 400 lat nieprzerwanego oglądania, aby zobaczyć wszystkie TikToki dodane TYLKO dzisiaj na platformie.**



Rozwój algorytmów uczenia maszynowego w latach 90.

- ▶ Algorytmy takie jak Support Vector Machines (SVM) i Random Forests zyskały popularność dzięki swojej elastyczności i mocnemu matematycznemu podłożu.
- ▶ Mimo że sieci neuronowe były już znane, ich zastosowanie wymagało zbyt dużego nakładu mocy obliczeniowej.



Ulepszenia technologiczne i mocniejsze komputery

- ▶ **Karty graficzne (GPU):** Ulepszony hardware graficzny, który okazał się być wyjątkowo efektywny w przyspieszaniu obliczeń wymaganych w algorytmach głębokiego uczenia.
- ▶ **Era Deep Learning:** Rozwój GPU w latach 2000. umożliwił powstanie i szybki rozwój głębokiego uczenia, revolutionizując dziedziny takie jak rozpoznawanie obrazów i przetwarzanie języka naturalnego.



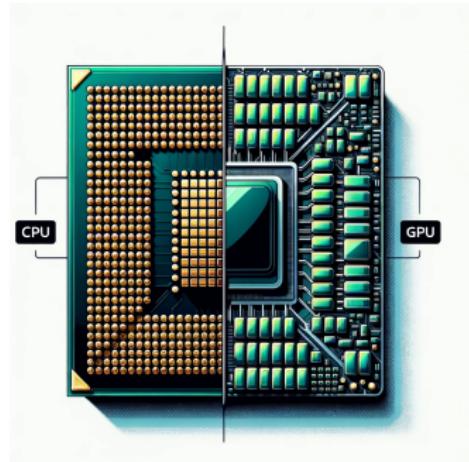
Karty graficzne (GPU) a głębokie uczenie

► CPU:

- ▶ Zoptymalizowany do zarządzania systemem i koordynowania pracy różnych części komputera.
- ▶ Specjalizuje się w zadaniach wymagających trudnych obliczeń.

► GPU:

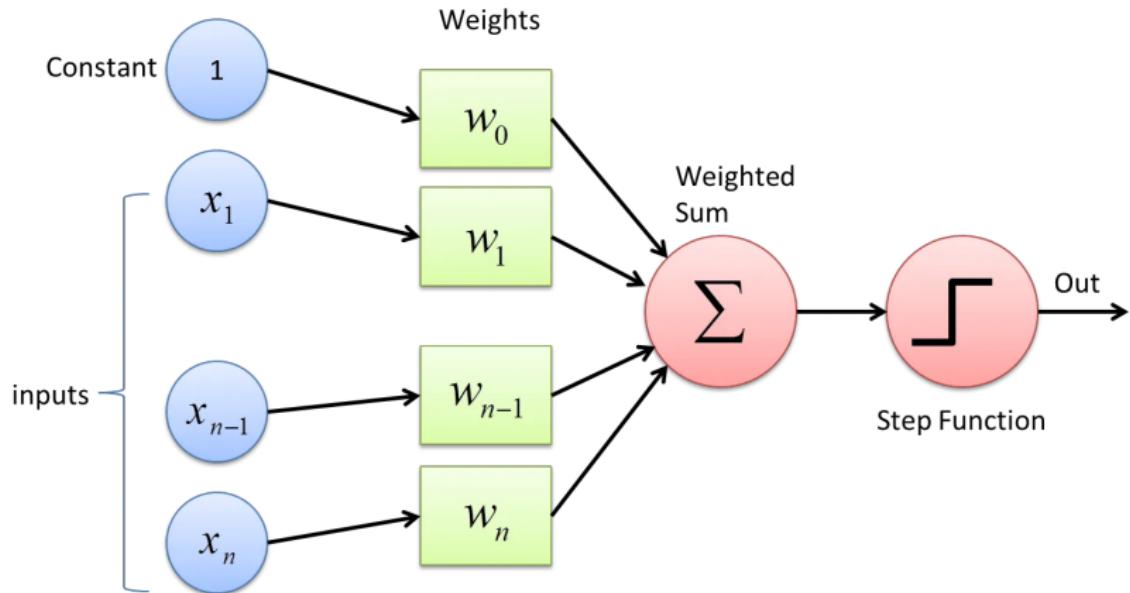
- ▶ Specjalizuje się w wykonywaniu wielu obliczeń matematycznych jednocześnie.
- ▶ Idealny do zadań związanych z głębokim uczeniem, które wymagają dużej ilości prostych operacji matematycznych.



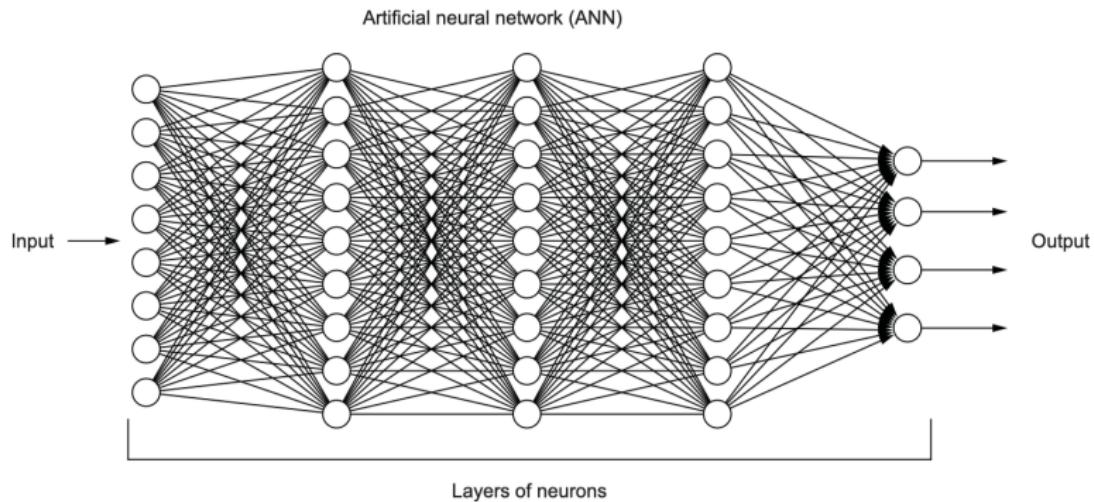
GPU: Klucz do przejścia od Machine Learning do Deep Learning

- ▶ **Proste operacje:** Głębokie uczenie, zwłaszcza sieci neuronowe, polega głównie na prostych operacjach matematycznych takich jak dodawanie i mnożenie.
- ▶ **Więcej rdzeni w GPU:** Karty graficzne mają znacznie więcej rdzeni niż procesory CPU. Na przykład, nowoczesne GPU mogą mieć nawet 5000 rdzeni, podczas gdy typowe CPU może mieć do 32 rdzeni.
- ▶ **Wpływ na Deep Learning:** Wykorzystanie GPU umożliwiło naukowcom trenowanie głębokich i złożonych modeli, co było trudne do osiągnięcia przy użyciu tylko CPU.

Perceptron

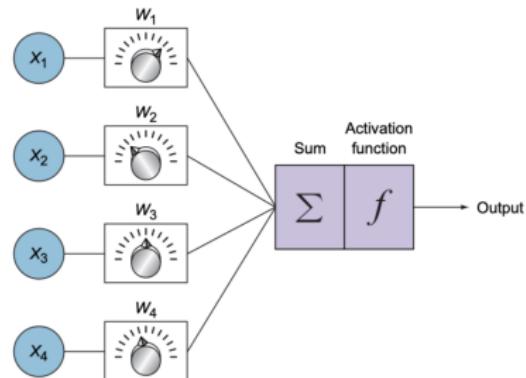


Sieć Neuronowa (wiele perceptronów)

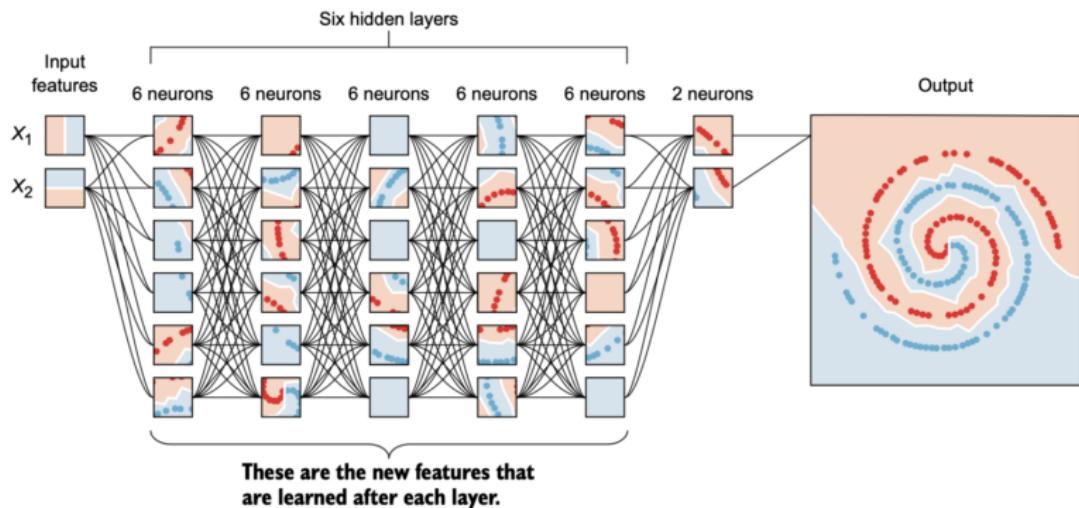


Jak działają sieci neuronowe?

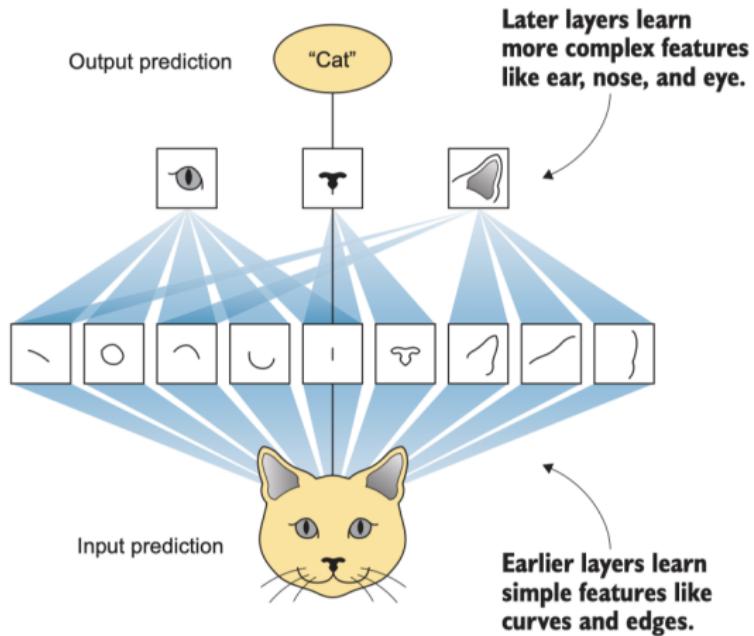
- ▶ Sieci neuronowe używają "neuronów" połączonych "wagami", które działają jak przełączniki.
- ▶ Wagi "sterują" tym, jak silny jest wpływ jednego neuronu na drugi.
- ▶ Sieć "uczy się" poprzez dostosowywanie tych wag, tak aby lepiej przewidywać odpowiedzi na podstawie danych wejściowych.



Sieć Neuronowa (wiele perceptronów)



Cechy (features)



Agenda

1. Historia i rozwój AI
2. **Przerwa**
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. QA - Sesja pytań i odpowiedzi

Agenda

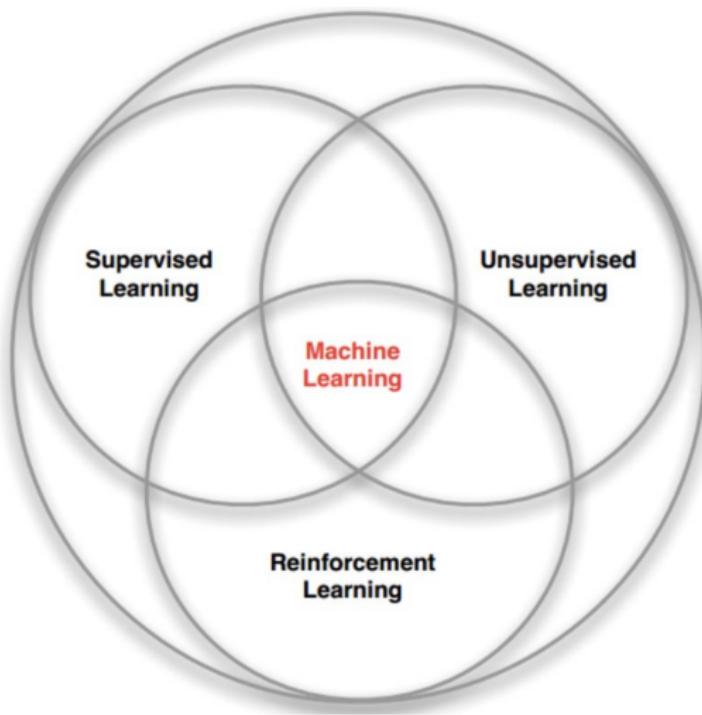
1. Historia i rozwój AI
2. Przerwa
3. **Podstawy uczenia maszynowego i uczenia głębokiego**
4. QA - Sesja pytań i odpowiedzi

Co to jest uczenie maszynowe?

- ▶ Uczenie maszynowe to sposób, aby komputery uczyły się od danych.
- ▶ Komputery mogą uczyć się rozpoznawać wzorce, podejmować decyzje i przewidywać przyszłe wydarzenia.
- ▶ Przykłady: Filtrowanie spamu w e-mailach, rekomendacje filmów, prognozowanie pogody.



Typy uczenia maszynowego



Typy uczenia maszynowego

- ▶ **Uczenie nadzorowane (Supervised Learning):** Model uczy się na podstawie **oznaczonych danych** i przewiduje wyniki na podstawie nowych danych. Przykłady to regresja i klasyfikacja.
- ▶ **Uczenie nienadzorowane (Unsupervised Learning):** Model uczy się wykrywać wzorce w danych, które nie są oznaczone. Przykłady to klasteryzacja i redukcja wymiarowości.
- ▶ **Uczenie przez wzmacnianie (Reinforcement Learning):** Model uczy się podejmować decyzje, wykonując akcje w środowisku, aby uzyskać jak największą nagrodę. ❤

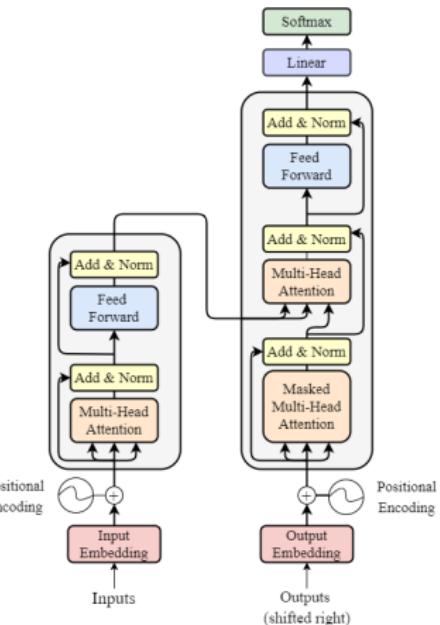
Co to jest głębokie uczenie?

- ▶ Głębokie uczenie to część uczenia maszynowego oparta na **sieciach neuronowych**
- ▶ Umożliwia komputerom naukę z dużych ilości danych.
- ▶ Przykłady: Rozpoznawanie obrazów, generowanie tekstu, tłumaczenie języków.

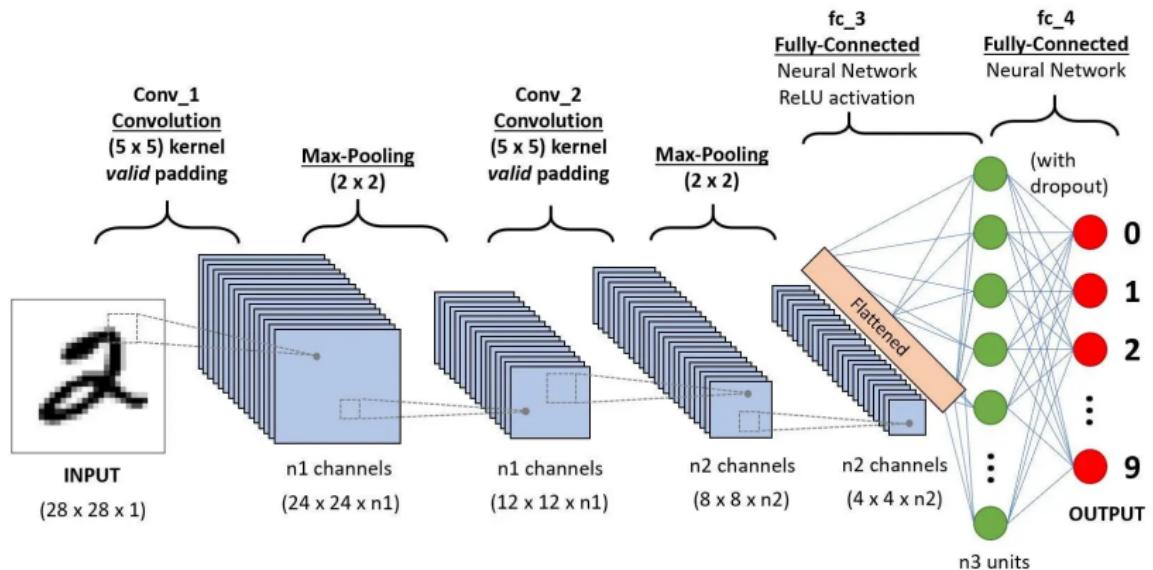


Czy sieci neuronowe są naprawdę tak potężne?

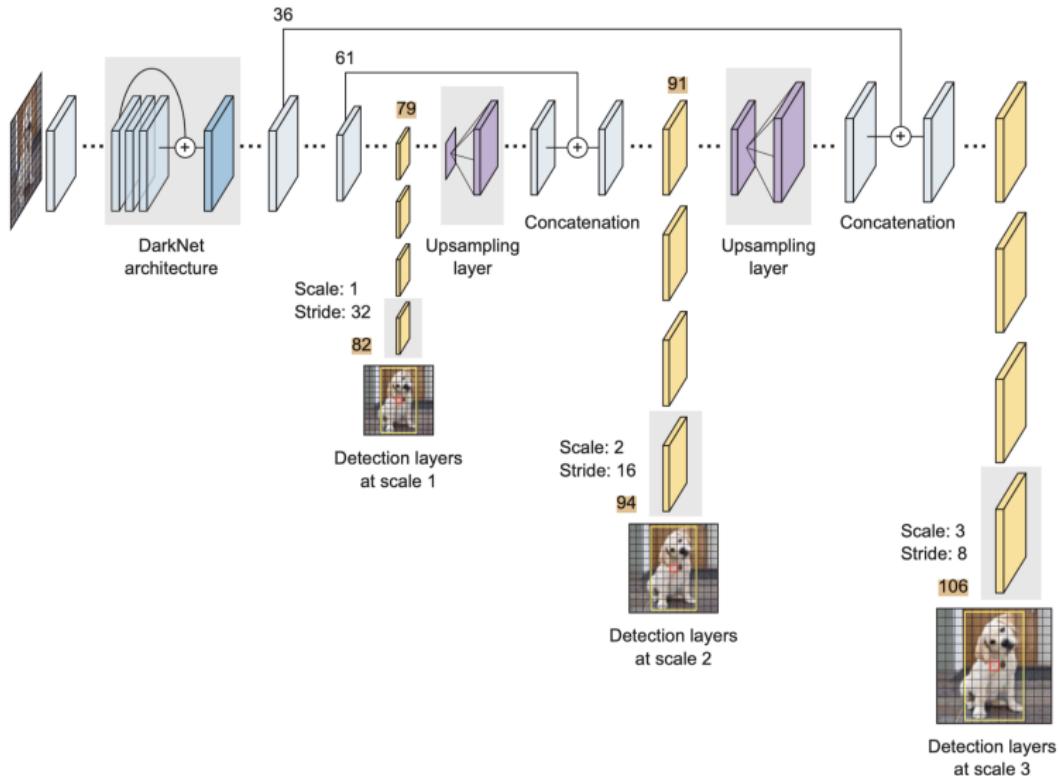
- ▶ Sieci neuronowe to potężne narzędzia, ale same w sobie **nie są "magiczne"**.
To sposób, w jaki są używane w różnych architekturach i modelach, sprawia, że są skuteczne.
- ▶ Często słyszymy, że "sieci neuronowe osiągnęły coś niesamowitego", ale prawda jest taka, że to **złożone modele i algorytmy, które wykorzystują sieci neuronowe**, osiągają te wyniki.



Convolutional Neural Network



You Only Look Once (YOLO)



Jak działa uczenie nadzorowane?

Nauczyciel w świecie maszyn: Uczenie Nadzorowane

- ▶ **Nauczyciel:** W uczeniu nadzorowanym, "nauczyciel" (człowiek) pokazuje komputerowi, co ma się nauczyć, podając **przykłady danych i odpowiednich etykiet**.
- ▶ **Książka z odpowiedziami:** Podobnie jak w szkolnej książce z odpowiedziami, komputer otrzymuje zestaw pytań **wraz z odpowiedziami (etykiety)**, które pomagają mu się uczyć.



Problemy rozwiązywane przez uczenie nadzorowane

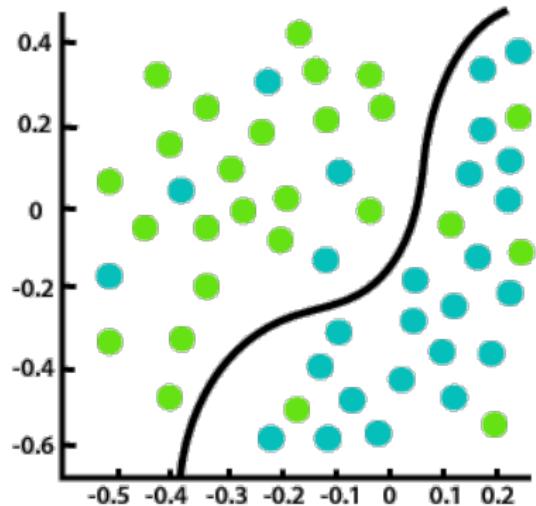
► Regresja:

- ▶ Przewidywanie ciągłych wartości.
- ▶ Przykład: Estymacja ceny mieszkania na podstawie jego lokalizacji, rozmiaru i cech.

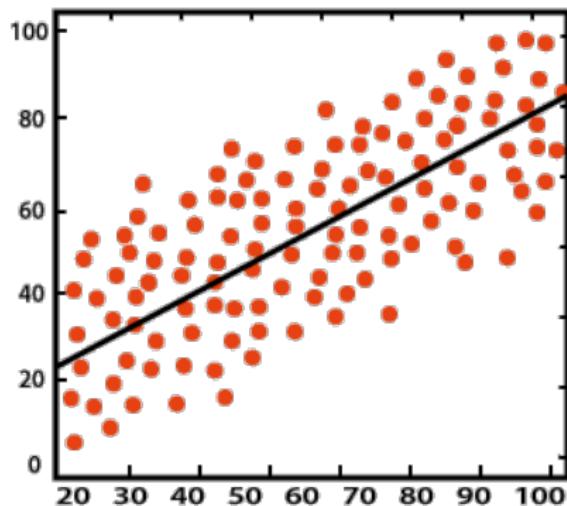
► Klasifikacja:

- ▶ Przewidywanie dyskretnych etykiet.
- ▶ Przykład: Rozpoznawanie kotków i piesków na zdjęciach.

Klasyfikacja oraz regresja



Classification



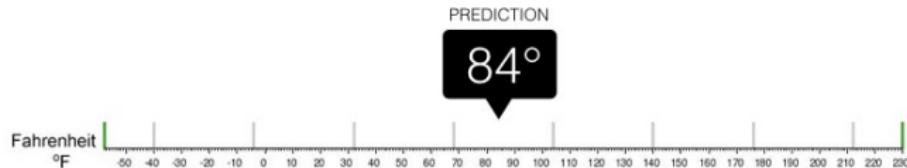
Regression

Klasyfikacja oraz regresja



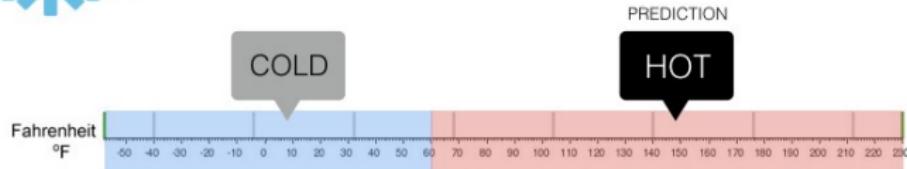
Regression

What is the temperature going to be tomorrow?



Classification

Will it be Cold or Hot tomorrow?



Czym są dane oznaczone ?

- ▶ **Oznaczone odpowiedziami:** Dane oznaczone zawierają informacje wejściowe oraz odpowiadające im etykiety, które służą jako odpowiedzi.
- ▶ **Podstawa uczenia nadzorowanego:** Dzięki etykietom, model uczenia maszynowego może nauczyć się rozpoznawać wzorce i dokonywać przewidywań.

Dane označzone

Labeled data



Dog



Dog

Labeled data



18 pounds



14 pounds

Unlabeled data



Cat



Cat



12 pounds

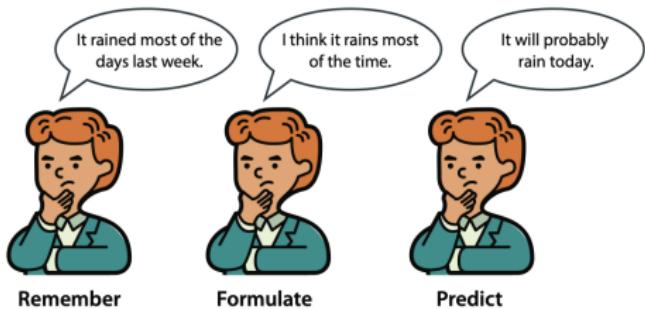


9 pounds

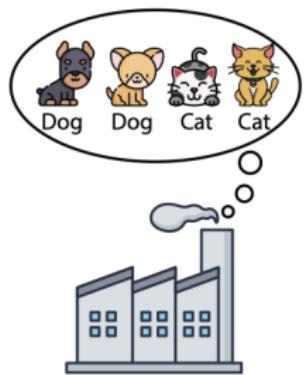


Jak działa uczenie nadzorowane?

- ▶ **Zapamiętanie:** Model uczy się na podstawie danych historycznych, które są "oznaczone" odpowiedziami.
- ▶ **Formułowanie:** Na podstawie tych danych, model "formułuje" zależności i wzorce.
- ▶ **Predykcja:** Używając nauczonych wzorców, model jest w stanie przewidywać przyszłe zdarzenia.



Klasyfikator piesków i kotków



Remember

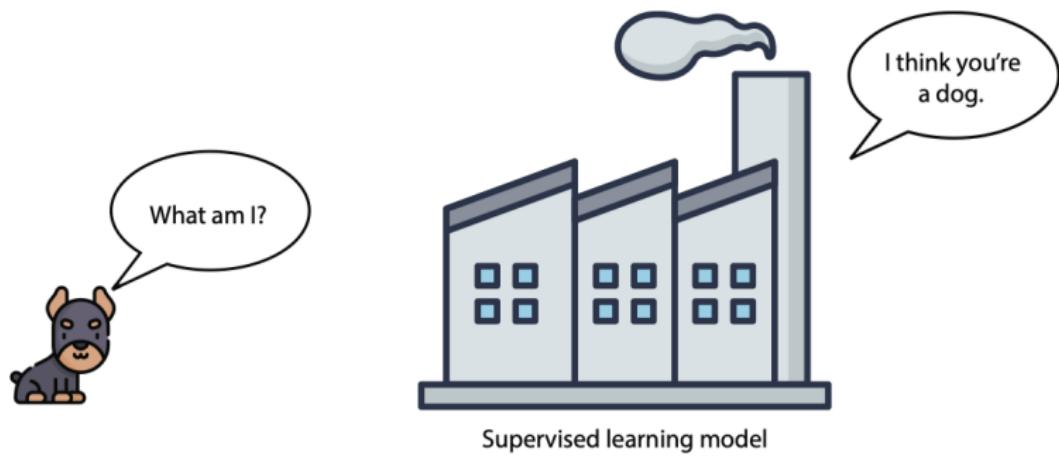


Formulate



Predict

Klasyfikator piesków i kotków



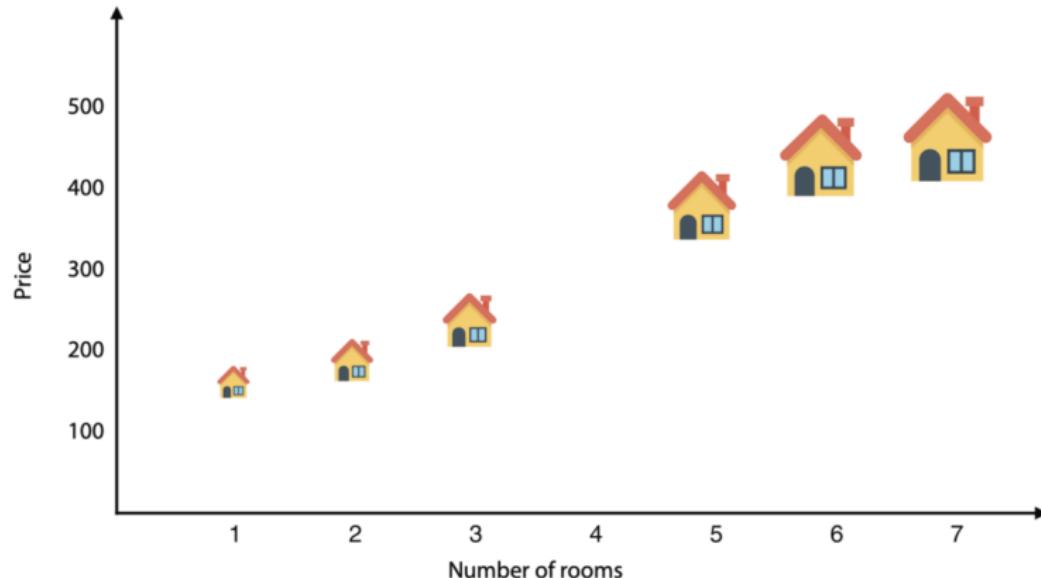
Regresja ceny mieszkań (R-F-P)



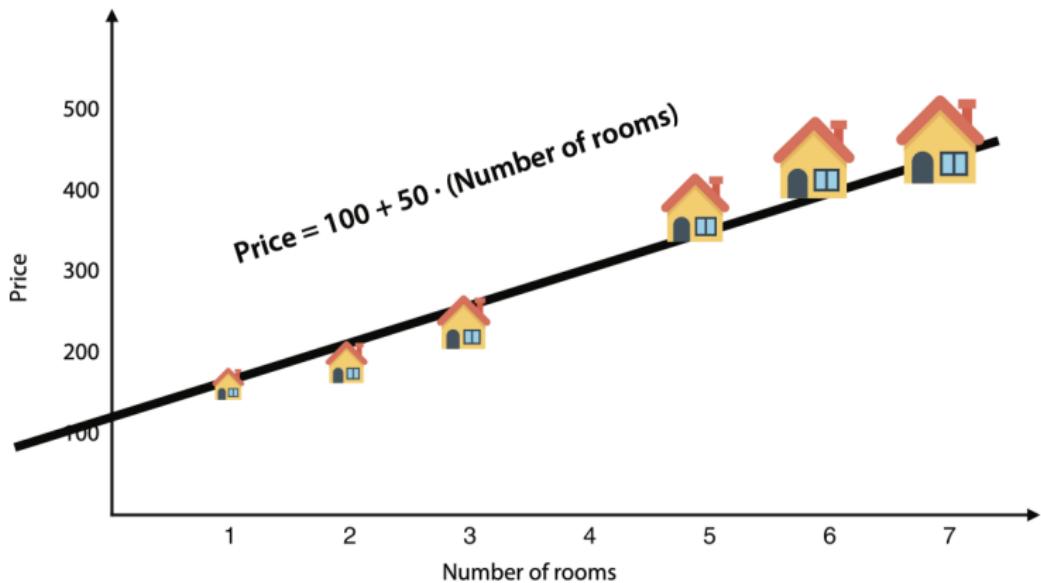
Cena mieszkania w.r.t ilości pokoi

| Number of rooms | Price |
|-----------------|-------|
| 1 | 150 |
| 2 | 200 |
| 3 | 250 |
| 4 | ? |
| 5 | 350 |
| 6 | 400 |
| 7 | 450 |

Step 1. R-remember (Zapamiętywanie danych oraz etykiet)



Step 2. Formulate (Formułowanie Zasad)

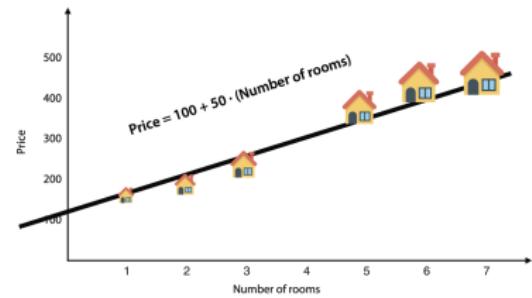


Cena mieszkania w.r.t ilości pokoi

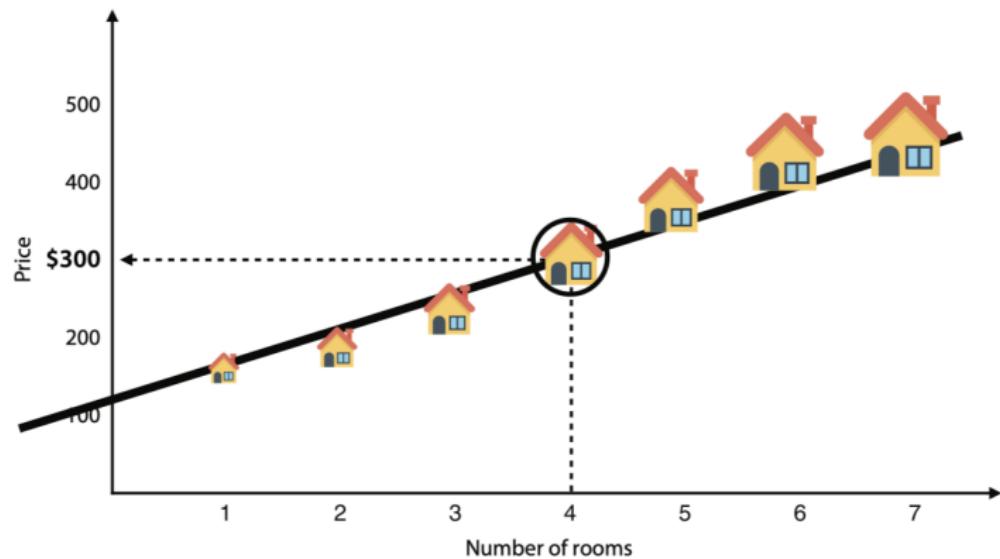
| Number of rooms | Price |
|-----------------|-------|
| 1 | 155 |
| 2 | 197 |
| 3 | 244 |
| 4 | ? |
| 5 | 356 |
| 6 | 407 |
| 7 | 448 |

Step 3. P-redict (Predykcja etykiet których nie znamy)

| Number of rooms | Price |
|-----------------|-------|
| 1 | 155 |
| 2 | 197 |
| 3 | 244 |
| 4 | ? |
| 5 | 356 |
| 6 | 407 |
| 7 | 448 |

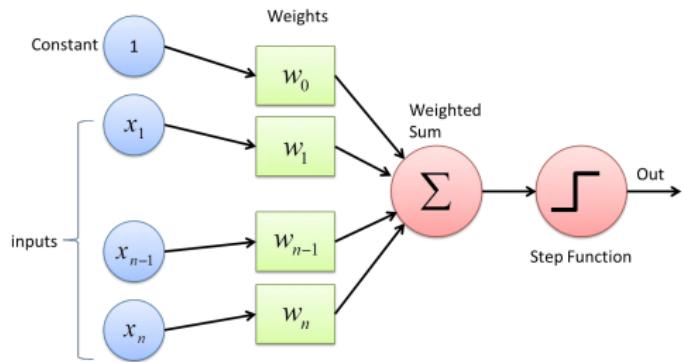


Step 3. P-redict (Predykcja etykiet których nie znamy)

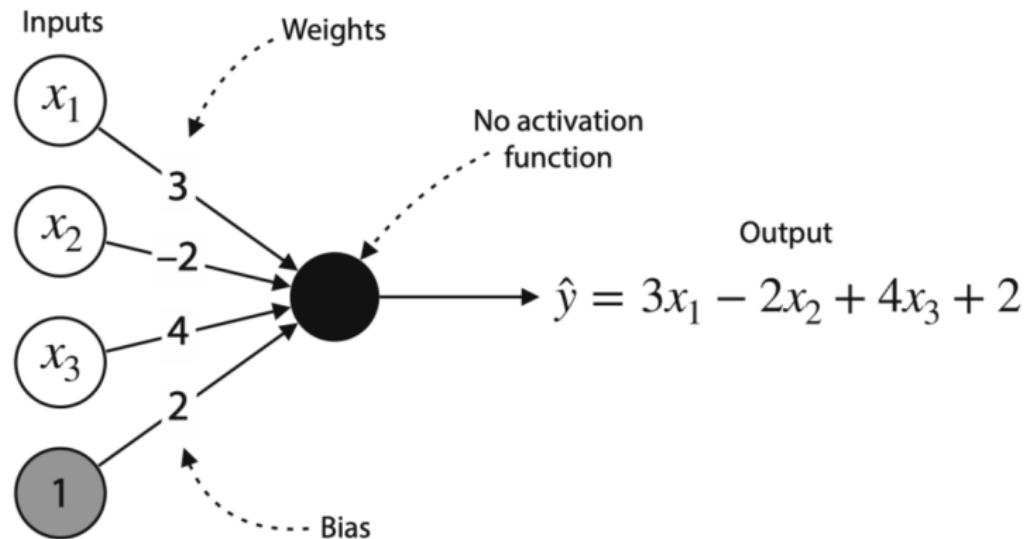


Perceptron: równanie liniowe i funkcja aktywacji

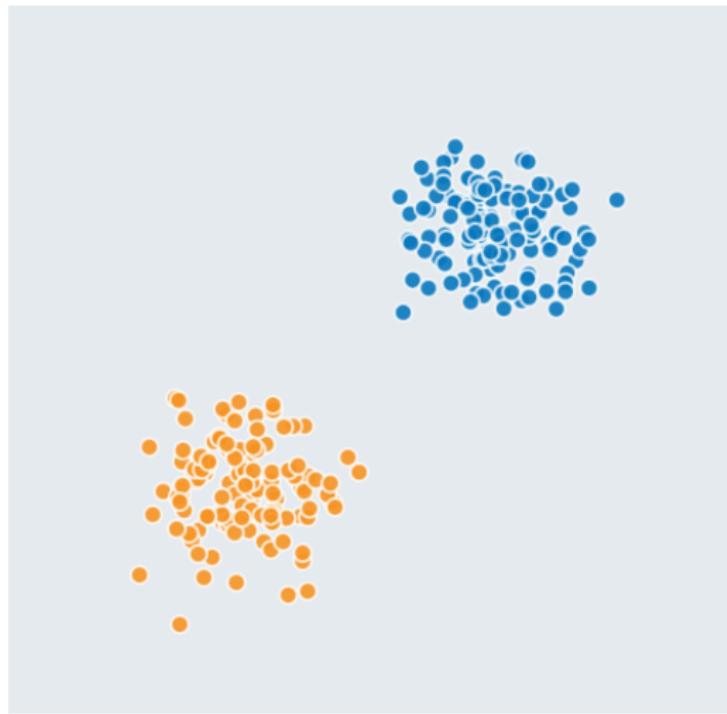
- ▶ Perceptron Składa się z **równania liniowego**, które sumuje wejścia pomnożone przez ich wagi,
- ▶ $\sum_{i=1}^n w_i x_i + b$
- ▶ gdzie w_i to waga i -tego wejścia x_i , a b to wyraz wolny (bias).



Równanie bez aktywacji



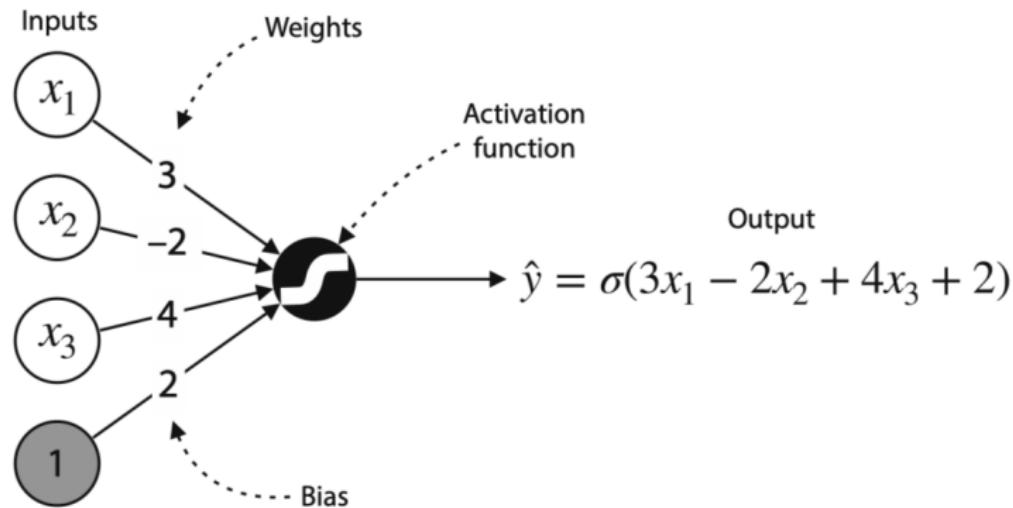
Dane które można separować liniowo



Funkcja liniowa to za mało

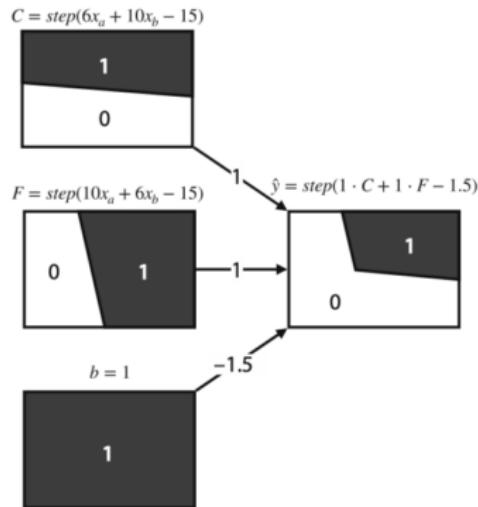


Równanie z aktywacją

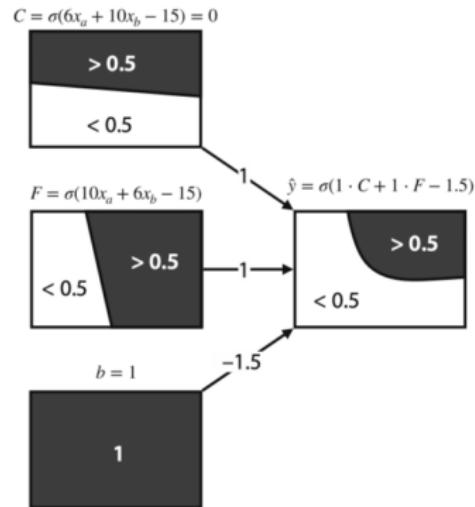


Przewaga aktywacji

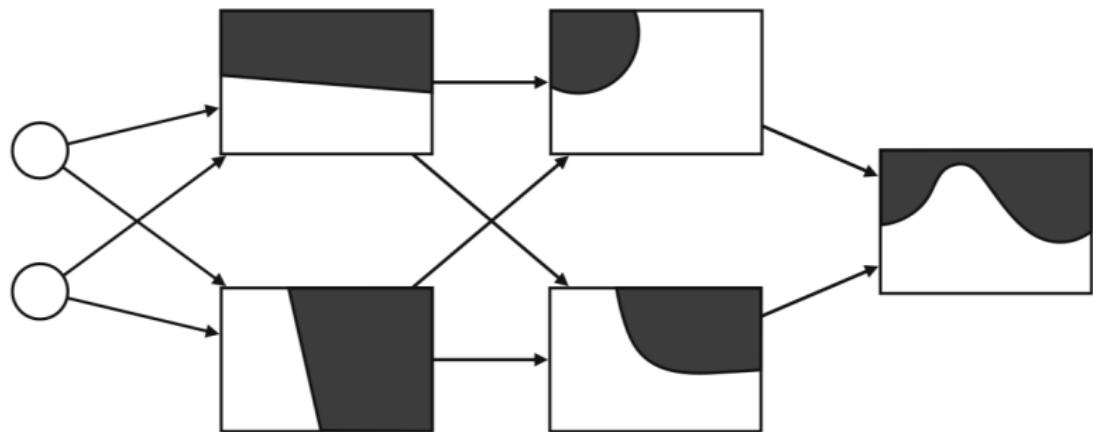
With the step activation function



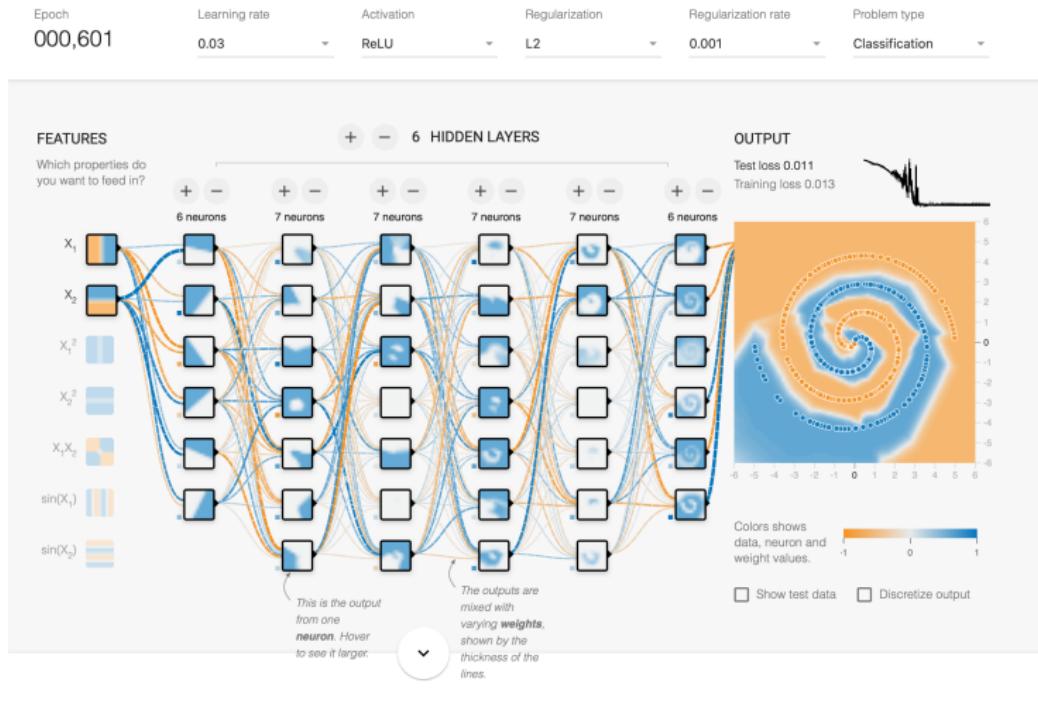
With the sigmoid activation function



Nieliniowe wzorce



Sieć neuronowa z aktywacją

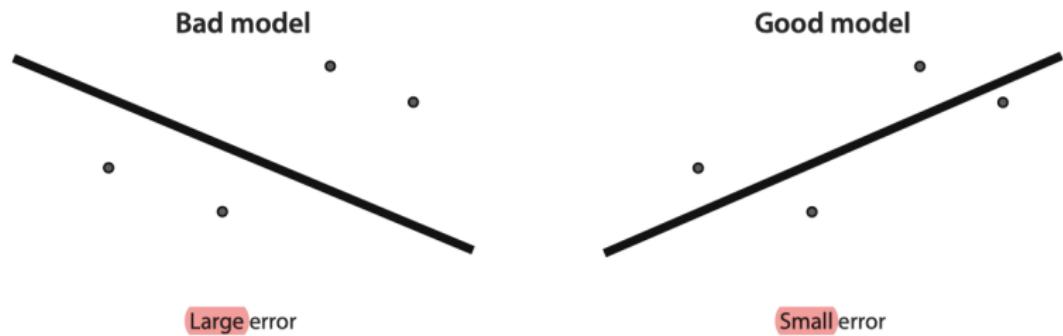


Co w przypadku gdy model się
pomyli?

Uczenie modelu poprawnego zachowania

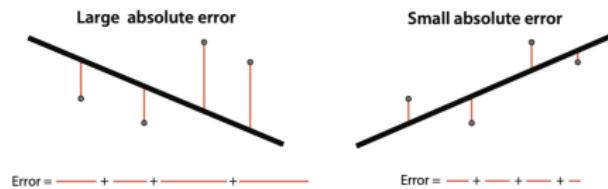


Dobre oraz złe zachowanie - regresja ceny mieszkań



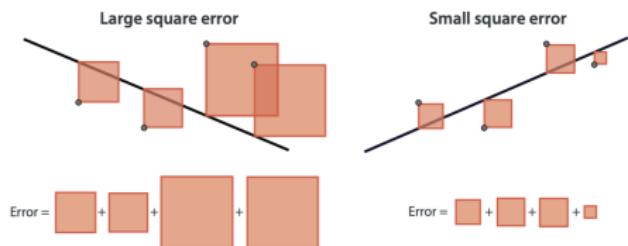
Funkcja straty L1 (MAE)

- ▶ **Definicja:** L1, czyli błąd bezwzględny średni (MAE),
- ▶ mierzy średnią wartość bezwzględnych różnic między przewidywaniami a rzeczywistymi wartościami.

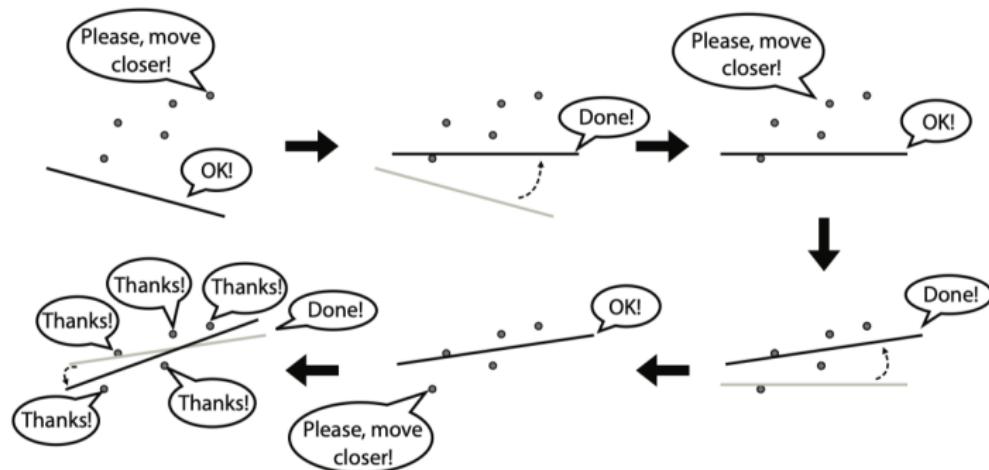


Funkcja straty L2 (MSE)

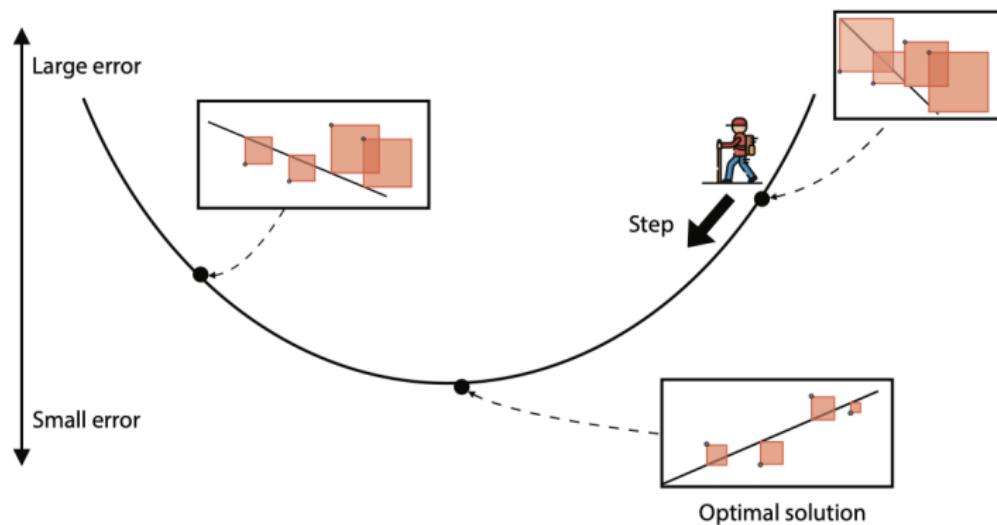
- ▶ **Definicja:** L2, czyli błąd średniokwadratowy (MSE),
- ▶ mierzy średnią wartość kwadratów różnic między przewidywaniami a rzeczywistymi wartościami.



Co mówi błąd do modelu



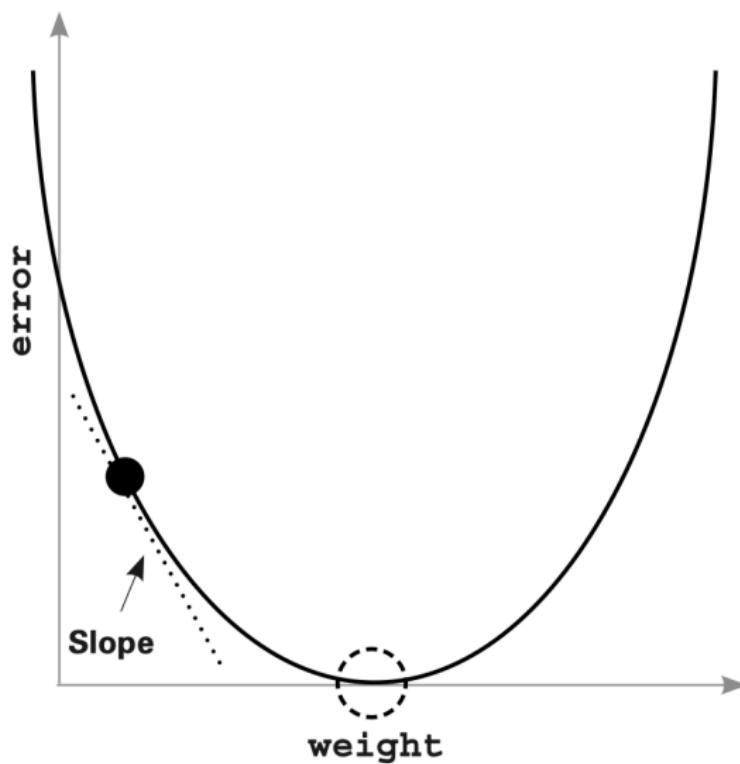
Minimalizacja błędu



Skąd model wie jak iść "w dół" ?

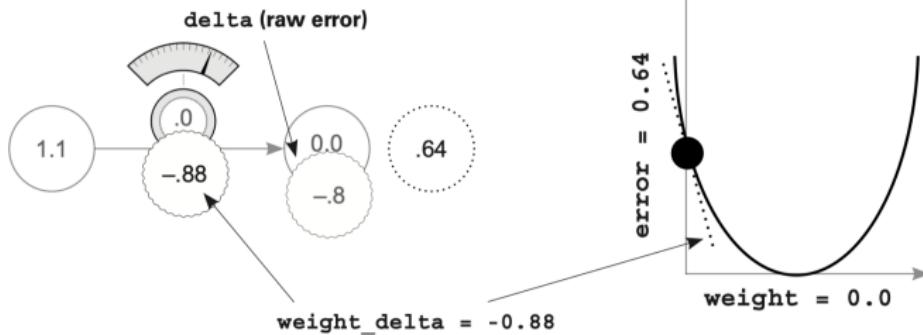


Pochodna funkcji straty



Iteracja 1

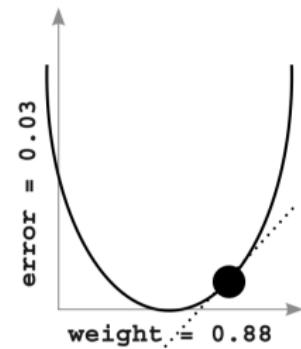
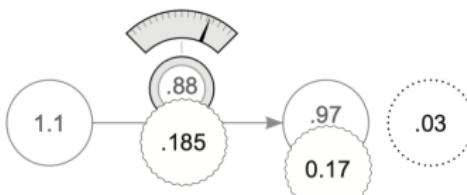
① A big weight increase



(Raw error modified for
scaling, negative reversal,
and stopping per this weight
and input)

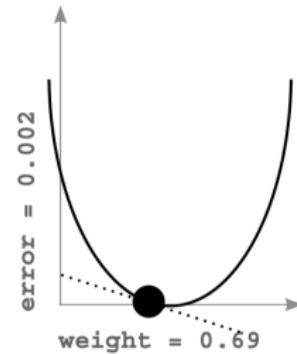
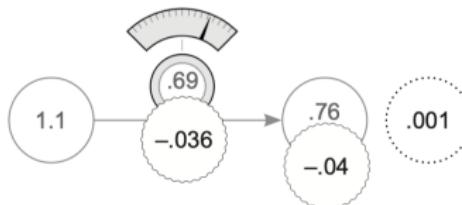
Iteracja 2

- ② Overshot a bit; let's go back the other way.



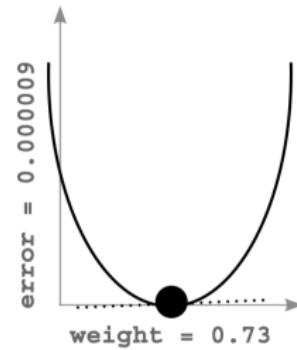
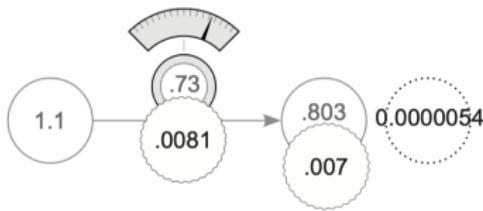
Iteracja 3

③ Overshot again! Let's go back, but only a little.



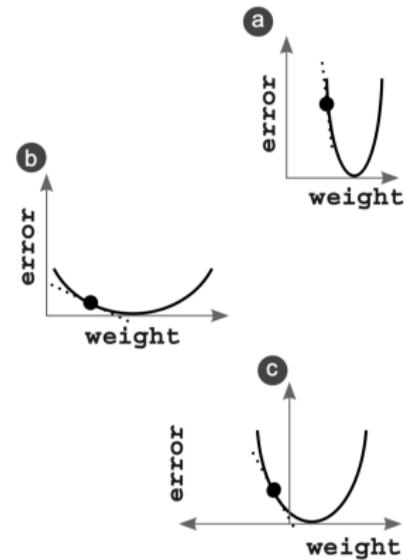
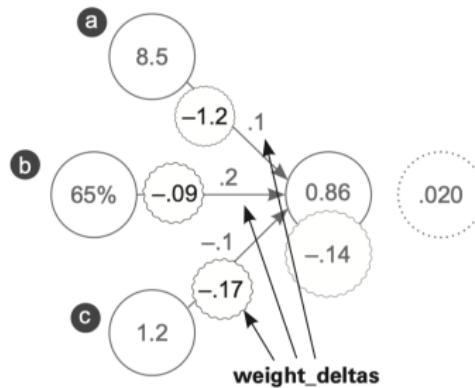
Iteracja 4

④ OK, we're pretty much there.



Gradient

① Iteration



Podsumowanie: Uczenie maszynowe i jego aspekty

- ▶ Uczenie maszynowe to dziedzina sztucznej inteligencji skoncentrowana na rozwijaniu algorytmów, które mogą uczyć się z danych i dokonywać prognoz lub decyzji bez jawnego programowania.
- ▶ Uczenie nadzorowane, jedna z głównych kategorii uczenia maszynowego, zajmuje się problemami regresji i klasyfikacji poprzez analizowanie danych etykietowanych.
- ▶ Sieci neuronowe wykorzystują funkcje aktywacji do wprowadzania nieliniowości w procesie uczenia, co pozwala na modelowanie skomplikowanych wzorców w danych.
- ▶ Gradient, czyli zbiór pochodnych cząstkowych (dla każdej wagi) pozwala na oszacowanie kroku w celu minimalizacji błędu.

Agenda

1. Historia i rozwój AI
2. Przerwa
3. Podstawy uczenia maszynowego i uczenia głębokiego
4. **QA - Sesja pytań i odpowiedzi**